



ΔΗΜΟΚΡΙΤΕΙΟ
ΠΑΝΕΠΙΣΤΗΜΙΟ
ΘΡΑΚΗΣ

ΤΜΗΜΑ
ΠΟΛΙΤΙΚΩΝ ΜΗΧΑΝΙΚΩΝ
ΤΜΗΜΑ
ΗΛΕΚΤΡΟΛΟΓΩΝ
ΜΗΧΑΝΙΚΩΝ &
ΜΗΧΑΝΙΚΩΝ ΥΠΟΛΟΓΙΣΤΩΝ
ΤΜΗΜΑ
ΜΗΧΑΝΙΚΩΝ
ΠΕΡΙΒΑΛΛΟΝΤΟΣ

ΔΙΑΤΜΗΜΑΤΙΚΟ

ΠΡΟΓΡΑΜΜΑ
ΜΕΤΑΠΤΥΧΙΑΚΩΝ
ΣΠΟΥΔΩΝ

ΕΦΑΡΜΟΣΜΕΝΑ
ΜΑΘΗΜΑΤΙΚΑ

APPLIED
MATHEMATICS

ΜΕΤΑΠΤΥΧΙΑΚΗ ΕΡΓΑΣΙΑ
MSc THESIS

Σπανός Μάρκος
Α.Μ. 1736

Ανάπτυξη προτύπων μηχανικής
μάθησης για την διάγνωση διαταραχών
του ήπατος με κλινικά δεδομένα

ΘΕΣΣΑΛΟΝΙΚΗ

Ιανουάριος 2025



«ΔΗΜΟΚΡΙΤΕΙΟ ΠΑΝΕΠΙΣΤΗΜΙΟ ΘΡΑΚΗΣ»

ΤΜΗΜΑ ΠΟΛΙΤΙΚΩΝ ΜΗΧΑΝΙΚΩΝ
ΤΜΗΜΑ ΗΛΕΚΤΡΟΛΟΓΩΝ ΜΗΧ. & ΜΗΧ. ΥΠΟΛΟΓΙΣΤΩΝ
ΤΜΗΜΑ ΜΗΧΑΝΙΚΩΝ ΠΕΡΙΒΑΛΛΟΝΤΟΣ

ΔΙΑΤΜΗΜΑΤΙΚΟ ΠΡΟΓΡΑΜΜΑ
ΜΕΤΑΠΤΥΧΙΑΚΩΝ ΣΠΟΥΔΩΝ
«ΕΦΑΡΜΟΣΜΕΝΑ ΜΑΘΗΜΑΤΙΚΑ»

Η μεταπτυχιακή εργασία του Σπανού Μάρκου (Α.Μ. 1736) με τίτλο:

«Ανάπτυξη προτύπων μηχανικής μάθησης για την διάγνωση διαταραχών του ήπατος με κλινικά δεδομένα»,

εξετάστηκε και εγκρίθηκε ως προς το περιεχόμενό της και την παρουσίαση.

	ονοματεπώνυμο	βαθμίδα	βαθμός	υπογραφή
Επιβλέπων	1. Α. Ηλιάδης	Καθηγητής		
Μέλος	2. Β. Παπαδόπουλος	Καθηγητής		
Μέλος	3. Α. Κογκέτσωφ	Καθηγητής		

Η εξεταστική επιτροπή

Ημερομηνία παρουσίασης:

ΔΗΜΟΚΡΙΤΕΙΟ ΠΑΝΕΠΙΣΤΗΜΙΟ ΘΡΑΚΗΣ
ΤΜΗΜΑ ΠΟΛΙΤΙΚΩΝ ΜΗΧΑΝΙΚΩΝ
ΤΜΗΜΑ ΗΛΕΚΤΡΟΛΟΓΩΝ ΜΗΧΑΝΙΚΩΝ ΚΑΙ ΜΗΧΑΝΙΚΩΝ ΥΠΟΛΟΓΙΣΤΩΝ
ΤΜΗΜΑ ΜΗΧΑΝΙΚΩΝ ΠΕΡΙΒΑΛΛΟΝΤΟΣ

Δια τμηματικό Πρόγραμμα Μεταπτυχιακών Σπουδών
«ΕΦΑΡΜΟΣΜΕΝΑ ΜΑΘΗΜΑΤΙΚΑ» (Ο.Δ.Τ.Σ.) © 2015

Η παρούσα Μεταπτυχιακή Διατριβή και τα συμπεράσματα αυτής σε οποιαδήποτε μορφή αποτελούν ιδιοκτησία αφ' ενός του συγγραφέως και αφ' ετέρου των Τμημάτων που συμμετέχουν στο Διατμηματικό Πρόγραμμα Μεταπτυχιακών Σπουδών (Δ.Π.Μ.Σ.). Τα ως άνω μέρη διατηρούν ανεξαρτήτως το δικαίωμα χρήσης και αναπαραγωγής (μέρους ή του συνόλου) του ουσιώδους περιεχομένου της παρούσας διατριβής για διδακτικούς και ερευνητικούς σκοπούς. Σε κάθε τέτοια περίπτωση η αναφορά στον τίτλο της διατριβής, τον συγγραφέα, τον επιβλέποντα και το Δ.Π.Μ.Σ. είναι υποχρεωτική.

Η έγκριση της παρούσας Μεταπτυχιακής Διατριβής από το Δ.Π.Μ.Σ. δεν συνιστά απαραίτητα αποδοχή των απόψεων του συγγραφέως από τα Τμήματα που μετέχουν σε αυτό.

Ο υπογραφόμενος δηλώνω υπεύθυνα ότι η παρούσα διατριβή είναι αποκλειστικά δικό μου έργο και υπεβλήθη στο Δ.Π.Μ.Σ. για να καλύψει μέρος των προ απαιτούμενων για την απόκτηση του Μεταπτυχιακού τίτλου στα Εφαρμοσμένα Μαθηματικά, ότι κατά την εκπόνηση της διατριβής σεβάστηκα τους όρους της Ακαδημαϊκής Ακεραιότητας και της Ερευνητικής Ηθικής και απέφυγα κάθε πράξη που συνιστά λογοκλοπή. Γνωρίζω, τέλος, ότι η λογοκλοπή μπορεί να τιμωρηθεί με αφαίρεση του Μεταπτυχιακού μου Τίτλου Σπουδών.

Υπογραφή

Φοιτητής

Σπανός Μάρκος

Πρόλογος

Το ανθρώπινο ήπαρ, ένα ζωτικό όργανο υπεύθυνο για πολυάριθμες μεταβολικές και αποτοξινωτικές διαδικασίες, είναι ολοένα και πιο ευάλωτο σε διάφορες διαταραχές που απαιτούν έγκαιρη ιατρική παρέμβαση. Η έγκαιρη διάγνωση των ηπατικών ασθενειών είναι υψίστης σημασίας, καθώς η καθυστερημένη ανίχνευση μπορεί να οδηγήσει σε μη αναστρέψιμη βλάβη, ξεπερνώντας το στάδιο στο οποίο η νόσος είναι ιάσιμη. Ένα σημαντικό μέρος της κατανόησης μας για την ανάπτυξη των οργάνων έχει προκύψει από εκτενείς αναλύσεις ασθενών που πάσχουν από ηπατικές ανεπάρκειες. Σε αυτό το πλαίσιο, η εξόρυξη δεδομένων έχει αποδειχθεί ένα αποτελεσματικό εργαλείο για την έγκαιρη ανίχνευση ηπατικών ασθενειών, αξιοποιώντας παράγοντες που προκύπτουν από λεπτομερείς ιατρικές εξετάσεις.

Στη σύγχρονη κοινωνία, οι διατροφικές συνήθειες διαδραματίζουν καθοριστικό ρόλο στην υγεία του ήπατος. Στην Ινδία, περίπου το 65% του πληθυσμού καταναλώνει τακτικά επεξεργασμένα και ανθυγιεινά τρόφιμα, γεγονός που μειώνει σημαντικά τη μεταβολική απόδοση και επηρεάζει αρνητικά τη λειτουργία του ήπατος. Τα τελευταία χρόνια, η συχνότητα εμφάνισης ηπατικών διαταραχών έχει αυξηθεί ανησυχητικά, θέτοντας σοβαρή απειλή για τη δημόσια υγεία, καθώς συνδέεται με υψηλά ποσοστά θνησιμότητας. Παρά τις προόδους στην ιατρική επιστήμη, η ανίχνευση ηπατικών παθήσεων εξακολουθεί να αποτελεί μια δύσκολη πρόκληση, καθώς τα συμπτώματά τους συχνά εκδηλώνονται με ήπιο τρόπο και είναι δύσκολο να διαγνωστούν. Η αδυναμία αναγνώρισης των πρώιμων ενδείξεων μπορεί να οδηγήσει σε σοβαρές επιπλοκές, αναδεικνύοντας έτσι την ανάγκη για ακριβείς και προληπτικές διαγνωστικές προσεγγίσεις.

Λαμβάνοντας υπόψη αυτές τις πειστικές ανησυχίες, η παρούσα μελέτη διερευνά την εφαρμογή της Ιατρικής Εξόρυξης Δεδομένων (Medical Data Mining - MDM) ως προγνωστικού εργαλείου για τη διάγνωση ηπατικών παθήσεων. Αναλύοντας ιστορικά ιατρικά δεδομένα και εντοπίζοντας επαναλαμβανόμενα πρότυπα, η MDM παρέχει ένα ισχυρό πλαίσιο για τη βελτίωση της έγκαιρης ανίχνευσης και την ενίσχυση των θεραπευτικών αποτελεσμάτων των ασθενών. Μέσω μιας συστηματικής διερεύνησης ιατρικών συνόλων δεδομένων, αυτή η έρευνα στοχεύει να συμβάλει στην ανάπτυξη πιο αποτελεσματικών διαγνωστικών μεθοδολογιών, προωθώντας την ιατρική περίθαλψη και μειώνοντας το παγκόσμιο βάρος των ηπατικών διαταραχών.

Ευχαριστίες

Σε αυτό το σημείο θα ήθελα να ευχαριστήσω θερμά τον επιβλέποντα καθηγητή της διπλωματικής μου εργασίας, Καθηγητή κ. Λάζαρο Ηλιάδη, για την άψογη συνεργασία που είχαμε και για την αμέριστη βοήθεια που μου προσέφερε με συμβουλές και υποδείξεις. Παράλληλα θα ήθελα να ευχαριστήσω τον Καθηγητή κ. Βασίλη Παπαδόπουλο και την Καθηγήτρια κ. Αυρηλία Κογκέτσωφ (μέλη της τριμελούς επιτροπής) για τις πολύ χρήσιμες υποδείξεις τους.

Περιεχόμενα

Πρόλογος	iii
Ευχαριστίες	iii
Περιεχόμενα.....	iv
Κατάλογος Ορολογιών, Συμβολισμών και Ακρωνύμων.....	vi
Περίληψη.....	vii
Abstract	viii
Κεφάλαιο 1. Αντικείμενο και διάρθρωση της Μ.Δ.Ε.	9
1.1. Εισαγωγή.....	9
1.2. Αντικείμενο της Μεταπτυχιακής Διατριβής Μ.Δ.	13
1.3. Διάρθρωση της διπλωματικής εργασίας.....	13
Κεφάλαιο 2. Ανάλυση διαταραχών του ήπατος.....	15
2.1. Εισαγωγή.....	15
2.2. Ιστολογία του ήπατος.....	15
2.3. Φυσιολογία του ήπατος	18
2.4. Κίρρωση ήπατος.....	18
Κεφάλαιο 3. Τεχνητή Νοημοσύνη.....	21
3.1. Εισαγωγή.....	21
3.2. Μηχανική Μάθηση	22
3.3. Τεχνητά Νευρωνικά Δίκτυα	23
3.4. Βαθιά Μάθηση (Deep Learning).....	24
3.5. Εξόρυξη Δεδομένων (Data Mining)	24
3.6. Ταξινόμηση (Classification)	25
3.7. Μέτρα απόδοσης μοντέλου	27
Κεφάλαιο 4. Ανασκόπηση βιβλιογραφίας	30
4.1. Εισαγωγή.....	30
4.2. Αλγόριθμοι επιλογής χαρακτηριστικών και ταξινόμησης παρατηρήσεων	31
4.3. Βιβλιογραφία ανίχνευσης ηπατικών παθήσεων	33
Κεφάλαιο 5. Έρευνα	37
5.1. Εισαγωγή.....	37
5.2. Δεδομένα.....	37

5.3. Περιγραφή των χαρακτηριστικών.....	38
5.4. Προ επεξεργασία δεδομένων στο excel.....	40
Κεφάλαιο 6. Αποτελέσματα της έρευνας	42
6.1. Εισαγωγή.....	42
6.2. Αποτελέσματα μετρικών των μοντέλων	43
6.3. Παρουσίαση γραφημάτων.....	44
6.3.2. Ανάλυση απόδοσης μοντέλων	48
Κεφάλαιο 7. Σύνοψη και συμπεράσματα	50
Σύνοψη.....	50
Συμπεράσματα και Προοπτικές.....	50
Βιβλιογραφία	52

Κατάλογος Ορολογιών, Συμβολισμών και Ακρωνύμων

ML	Machine Learning
SVM	Support Vector Machines
KNN	K Nearest Neighbors
NN	Neural Networks
XGBoost	Xtreme Gradient Boosting
AI	Artificial Intelligence
NLP	Natural Language Processing
ANN	Artificial Neural Networks
GA	Genetic Algorithms
DTs	Decision Trees
MDM	Medical Data Mining
EHR	Electronic Health Record
PCA	Principal Component Analysis
ROC	Receiver Operating Characteristic curve
AUC	Area Under the Curve
LMT	Logistic Model Tree
MLP	Multi Layer Perceptron
RBF	Radial Basis Function
NBTree	Naïve Bayes Tree
SMOTE	Synthetic Minority Over-sampling Technique
A/G	Albumin/Globulin

Περίληψη

Οι ηπατικές διαταραχές αποτελούν ένα παγκόσμιο ζήτημα υγείας, επηρεάζοντας εκατομμύρια ανθρώπους και συμβάλλουν σε υψηλά ποσοστά θνησιμότητας. Η έγκαιρη διάγνωση είναι κρίσιμη για την αποτελεσματική παρέμβαση και θεραπεία. Οι παραδοσιακές διαγνωστικές τεχνικές, όπως οι βιοχημικές εξετάσεις και η απεικόνιση, μπορεί να είναι δαπανηρές και χρονοβόρες, οδηγώντας σε καθυστερήσεις στη θεραπεία. Η ενσωμάτωση της μηχανικής μάθησης (ML) στη διάγνωση ασθενειών προσφέρει μια πολλά υποσχόμενη εναλλακτική λύση μέσω της αυτοματοποιημένης ανίχνευσης της ηπατικής νόσου με μοντελοποίηση πρόβλεψης και ανάλυση δεδομένων.

Αυτή η έρευνα εξετάζει την εφαρμογή διαφόρων μοντέλων ML για την πρόβλεψη ηπατικών νοσημάτων, αξιοποιώντας δεδομένα ασθενών από την Ινδία. Το σύνολο δεδομένων αποτελείται από πολλαπλούς βιοχημικούς δείκτες, συμπεριλαμβανομένων της χολερυθρίνης, της αλβουμίνης και των επιπέδων ενζύμων, οι οποίοι χρησιμεύουν ως βασικοί δείκτες της ηπατικής λειτουργίας.

Αξιολογούνται διάφοροι αλγόριθμοι ταξινόμησης, όπως Support Vector Machines (SVM), Logistic Regression, k-Nearest Neighbors (KNN), Decision Trees, Naïve Bayes, Neural Networks (NN), Bagging και Boosting Ensemble (XGBoost). Αυτά τα μοντέλα αξιολογούνται βάση συγκεκριμένων μετρήσεων που υποδεικνύουν τη συνολική απόδοση τους. Τα πειραματικά αποτελέσματα δείχνουν ότι τα Νευρωνικά Δίκτυα επιτυγχάνουν την υψηλότερη ακρίβεια και προγνωστική ισχύ, ακολουθούμενο από το XGBoost και το KNN. Αντίθετα, απλούστερα μοντέλα όπως το Logistic Regression και το Naïve Bayes παρουσίασαν χαμηλότερη απόδοση λόγω εγγενών περιορισμών στη διαχείριση πολύπλοκων, υψηλής διάστασης ιατρικών δεδομένων.

Τα ευρήματα αναδεικνύουν τη δυνατότητα των τεχνικών συνδυαστικής μάθησης (ensemble learning) και των μοντέλων βαθιάς μάθησης στη βελτίωση της διάγνωσης ηπατικών παθήσεων. Με την ενσωμάτωση αυτών των μοντέλων σε συστήματα υποστήριξης ιατρικών αποφάσεων, οι επαγγελματίες υγείας μπορούν να ενισχύσουν την ακρίβεια της διάγνωσης και να μειώσουν την εξάρτηση από επεμβατικές διαδικασίες.

Abstract

Liver disorders constitute a global health issue, affecting millions of people and contributing to high mortality rates. Early diagnosis is crucial for effective intervention and treatment. Traditional diagnostic techniques, such as biochemical tests and imaging, can be costly and time-consuming, leading to delays in treatment. The integration of machine learning (ML) into disease diagnosis offers a promising alternative through automated liver disease detection using predictive modeling and data analysis.

This research examines the application of various ML models for liver disease prediction, utilizing patient data from India. The dataset consists of multiple biochemical markers, including bilirubin, albumin, and enzyme levels, which serve as key indicators of liver function.

Several classification algorithms are evaluated, including Support Vector Machines (SVM), Logistic Regression, k-Nearest Neighbors (KNN), Decision Trees, Naïve Bayes, Neural Networks (NN), Bagging, and Boosting Ensemble (XGBoost). These models are assessed based on specific metrics that indicate their overall performance. Experimental results show that Neural Networks achieve the highest accuracy and predictive power, followed by XGBoost and KNN. In contrast, simpler models such as Logistic Regression and Naïve Bayes exhibited lower performance due to inherent limitations in handling complex, high-dimensional medical data.

The findings highlight the potential of ensemble learning techniques and deep learning models in improving liver disease diagnosis. By integrating these models into clinical decision support systems, healthcare professionals can enhance diagnostic accuracy and reduce dependence on invasive procedures.


Κεφάλαιο 1. Αντικείμενο και διάρθρωση της Μ.Δ.Ε.

1.1. Εισαγωγή

Η Τεχνητή Νοημοσύνη (AI) είναι ένας ταχέως εξελισσόμενος τομέας που επικεντρώνεται στην ανάπτυξη συστημάτων ικανών να εκτελούν εργασίες που συνήθως απαιτούν ανθρώπινη νοημοσύνη, όπως η επίλυση προβλημάτων, η λήψη αποφάσεων, η κατανόηση της γλώσσας και η αναγνώριση προτύπων. Η AI περιλαμβάνει διάφορους υποτομείς, όπως η υπολογιστική όραση (computer vision), η επεξεργασία φυσικής γλώσσας (NLP) και η ρομποτική, με εφαρμογές που εκτείνονται σε τομείς όπως η υγειονομική περίθαλψη, τα χρηματοοικονομικά και τα αυτόνομα συστήματα.

Η Μηχανική Μάθηση (ML) αποτελεί έναν από τους κλάδους της AI και επιτρέπει στους υπολογιστές να μαθαίνουν μοτίβα από δεδομένα και να κάνουν προβλέψεις. Αντί να βασίζονται σε προκαθορισμένους κανόνες, οι αλγόριθμοι ML βελτιώνουν την ακρίβειά τους με την πάροδο του χρόνου, αναλύοντας τεράστιες ποσότητες πληροφοριών. Οι τεχνικές ML διακρίνονται σε επιβλεπόμενη μάθηση (Supervised learning), όπου τα μοντέλα μαθαίνουν από δεδομένα με ετικέτες, μη επιβλεπόμενη μάθηση (Unsupervised learning), η οποία εντοπίζει πρότυπα σε μη επισημασμένα δεδομένα, και ενισχυτική μάθηση (Reinforcement Learning) όπου το σύστημα βελτιστοποιεί τις ενέργειές του μέσω ανατροφοδότησης.

Τα τελευταία χρόνια, η ML έχει φέρει επανάσταση σε διάφορους τομείς, ιδιαίτερα στην υγειονομική περίθαλψη, όπου συμβάλλει στη διάγνωση ασθενειών, την ανακάλυψη φαρμάκων και την εξατομικευμένη θεραπεία. Προηγμένα μοντέλα, όπως η βαθιά μάθηση (Deep Learning) και οι μέθοδοι συνδυαστικής μάθησης (Ensemble), έχουν επιδείξει εξαιρετική επιτυχία στην προγνωστική ανάλυση βελτιώνοντας σημαντικά τις διαδικασίες λήψης ιατρικών αποφάσεων.




Δύο από τις πιο θεμελιώδεις λειτουργίες της επιβλεπόμενης μηχανικής μάθησης είναι η ταξινόμηση (Classification) και η παλινδρόμηση (Regression), όπου τα μοντέλα μαθαίνουν να κάνουν προβλέψεις από δεδομένα με ετικέτες. Και οι δύο λειτουργίες κατέχουν σημαντικό ρόλο σε διάφορες εφαρμογές σε πολλούς κλάδους από την υγειονομική περίθαλψη και τα χρηματοοικονομικά έως τα αυτόνομα συστήματα και τις μηχανές σύστασης.

Ταξινόμηση

Η ταξινόμηση περιλαμβάνει την πρόβλεψη διακριτών ετικετών ή κατηγοριών. Το μοντέλο αναθέτει κάθε δείγμα εισόδου σε μια προκαθορισμένη κλάση, βασιζόμενο σε μοτίβα που έχει μάθει από τα δεδομένα. Χρησιμοποιείται ευρέως στην ιατρική διάγνωση, ανίχνευση ανεπιθύμητων μηνυμάτων (spam detection), ανάλυση συναισθήματος κ.α.

Παλινδρόμηση

Η παλινδρόμηση χρησιμοποιείται για την πρόβλεψη συνεχών αριθμητικών τιμών, αντί για διακριτές κατηγορίες. Βοηθά στην εκτίμηση των σχέσεων μεταξύ των μεταβλητών και την πραγματοποίηση ποσοτικών προβλέψεων. Οι εφαρμογές της περιλαμβάνουν πρόβλεψη χρηματιστηριακών τιμών, εκτίμηση τιμής ακινήτων, πρόγνωση καιρού κ.α.



Τα Τεχνητά Νευρωνικά Δίκτυα (Artificial Neural Networks ANN) είναι τυπικοί αλγόριθμοι Μηχανικής Μάθησης οι οποίοι μιμούνται την λειτουργία του ανθρώπινου εγκεφάλου για να αναγνωρίσουν σχέσεις ανάμεσα σε μεγάλους όγκους δεδομένων. Μαζί με τους Γενετικούς αλγόριθμους (Genetic Algorithms GA), τις Μηχανές Διανύσματος Υποστήριξης (Support Vector Machines SVM) και την Ασαφή Λογική αποτελούν τον πυρήνα ενός πολύ σημαντικού κεφαλαίου της ΤΝ που ονομάζεται Υπολογιστική Νοημοσύνη (Computational Intelligence).

Άλλες περιπτώσεις αλγορίθμων που παρουσιάζουν ενδιαφέρον είναι οι αλγόριθμοι Δέντρων Απόφασης (Decision Trees DTs), Random Forests, Naïve Bayes και K-Nearest Neighbors (KNN).

Σημαντικό ρόλο στην ανάπτυξη των συστημάτων αυτών αποτέλεσε η αποτελεσματικότητά τους και το ευρύ φάσμα εφαρμογής τους (ιατρική, επιχειρήσεις, διαχείριση σχέσεων με πελάτες, κτλ.). Πρόσφατες μελέτες προτείνουν την χρήση δομημένων πλαισίων που χρησιμοποιούν περισσότερους από έναν αλγόριθμους, οι οποίοι συνεργάζονται για την λύση ενός προβλήματος.

Η Μηχανική Μάθηση χρησιμοποιείται σε διαγνώσεις κλινικών περιπτώσεων μέσα από τον κλάδο της Ιατρικής Εξόρυξης Δεδομένων (MDM). Πρόκειται για την διαδικασία εφαρμογής τεχνικών εξόρυξης δεδομένων σε ιατρικά και υγειονομικά δεδομένα, με σκοπό την εξαγωγή σημαντικών μοτίβων, τάσεων και πληροφοριών που μπορούν να βελτιώσουν τη λήψη αποφάσεων και την περίθαλψη των ασθενών. Περιλαμβάνει τη χρήση μηχανικής μάθησης, στατιστικής ανάλυσης και τεχνητής νοημοσύνης (AI) για την ανάλυση μεγάλου όγκου δομημένων και μη δομημένων ιατρικών δεδομένων, όπως ηλεκτρονικοί ιατρικοί φάκελοι (EHRs), αποτελέσματα εργαστηριακών εξετάσεων, ιατρικές απεικονίσεις και γονιδιωματικά δεδομένα.

Η MDM διαδραματίζει κρίσιμο ρόλο στην πρόβλεψη ασθενειών, την αξιολόγηση κινδύνου ασθενών, την ανακάλυψη φαρμάκων και την εξατομικευμένη ιατρική, επιτρέποντας στους επαγγελματίες υγείας να λαμβάνουν τεκμηριωμένες κλινικές αποφάσεις βασισμένες σε δεδομένα. Μέσω τεχνικών ταξινόμησης, ομαδοποίησης και προγνωστικής μοντελοποίησης μπορεί να αποκαλύψει κρυμμένες συσχετίσεις σε ιατρικά δεδομένα, να εντοπίσει ανωμαλίες και να βελτιστοποιήσει τα θεραπευτικά πλάνα. Ωστόσο, προκλήσεις όπως η προστασία προσωπικών δεδομένων, τα ηθικά ζητήματα και η ανάγκη για υψηλής ποιότητας δεδομένα με ετικέτες παραμένουν κρίσιμα ζητήματα στην ευρεία εφαρμογή της.

Η κίρρωση του ήπατος είναι μια χρόνια ηπατική νόσος που χαρακτηρίζεται από την αντικατάσταση του υγιούς ηπατικού ιστού με ουλώδη ιστό, οδηγώντας σε προοδευτική απώλεια της ηπατικής λειτουργίας.

Σύμφωνα με τον Παγκόσμιο Οργανισμό Υγείας (ΠΟΥ), η κίρρωση προκύπτει από παρατεταμένη και εκτεταμένη ηπατοκυτταρική νέκρωση λόγω διαφόρων αιτιών, με τις πιο συχνές να είναι η αλκοολική ηπατική νόσος και η χρόνια ιογενής ηπατίτιδα Β και C.

Αναφέρει ότι η ηπατίτιδα Β και C είναι οι κύριες αιτίες κίρρωσης του ήπατος, καρκίνου του ήπατος και θανάτων που σχετίζονται με την ιογενή ηπατίτιδα παγκοσμίως.

Στις Ηνωμένες Πολιτείες, το 2022 καταγράφηκαν 54.803 θάνατοι από χρόνιες ηπατικές νόσους και κίρρωση, με δείκτη θνησιμότητας 16,4 θανάτους ανά 100.000 πληθυσμού.

Η κίρρωση αποτελεί την 11η πιο κοινή αιτία θανάτου παγκοσμίως, συμβάλλοντας σημαντικά στην παγκόσμια επιβάρυνση υγείας.

Επιπλέον, η θνησιμότητα από κίρρωση παρουσιάζει ανοδική τάση σε πολλές χώρες, υπογραμμίζοντας την ανάγκη για ενισχυμένες προσπάθειες πρόληψης και θεραπείας.

Τονίζει επίσης τη σημασία της αντιμετώπισης των βασικών αιτιών της κίρρωσης, όπως η ιογενής ηπατίτιδα και οι διαταραχές που σχετίζονται με την κατανάλωση αλκοόλ, προκειμένου να μειωθεί η παγκόσμια επιβάρυνση αυτής της ασθένειας.

Η έγκαιρη διάγνωση και η σωστή διαχείριση της κίρρωσης είναι ζωτικής σημασίας για την πρόληψη επιπλοκών και τη βελτίωση της υγείας των ασθενών.

1.2. Αντικείμενο της Μεταπτυχιακής Διατριβής Μ.Δ.

Εκτός από κλινικές εξετάσεις, μέθοδοι μηχανικής μάθησης και αναγνώρισης προτύπων και τεχνικές εξόρυξης δεδομένων (data mining) έχουν χρησιμοποιηθεί ευρέως στην ιατρική για την έγκαιρη διάγνωση ασθενειών.

Η τεχνητή νοημοσύνη χρησιμοποιείται για να εκπαιδεύει τους υπολογιστές να σκέφτονται όπως οι άνθρωποι, να μαθαίνουν από την εμπειρία και να αποφασίζουν βασιζόμενοι στην ανθρώπινη γνώση. Οι τεχνικές εξόρυξης δεδομένων (data mining) παρέχουν αποτελεσματικά εργαλεία επεξεργασίας μεγάλου συνόλου δεδομένων για την διάγνωση της ασθένειας και της σοβαρότητάς της.

Στόχος της παρούσας έρευνας είναι να αναπτύξει μοντέλα Μηχανικής Μάθησης τα οποία θα προβλέπουν αν ο ασθενής πάσχει από ηπατική νόσο ή όχι, με σκοπό την πρόληψη της κίρρωσης του ήπατος, σύμφωνα με τις ιατρικές ενδείξεις που έχουμε από το σετ δεδομένων.

1.3. Διάρθρωση της διπλωματικής εργασίας

Η παρούσα Μ.Δ. θα αναπτυχθεί σε 7 κεφάλαια με την εξής διάρθρωση:

Στο Κεφάλαιο 2 παρατίθενται οι βασικές ιατρικές γνώσεις σχετικά με τις διαταραχές του ήπατος. Αναλύεται η ιστολογία και φυσιολογία του ήπατος, περιγράφονται οι κύριες ηπατικές παθήσεις, όπως η ηπατίτιδα, η κίρρωση και ο ηπατοκυτταρικός καρκίνος, και εξετάζονται οι παράγοντες κινδύνου που συμβάλλουν στην ανάπτυξή

τους. Επιπλέον, παρουσιάζεται η συμπτωματολογία των παθήσεων του ήπατος, καθώς και οι διαγνωστικές μέθοδοι και οι διαθέσιμες θεραπευτικές προσεγγίσεις.

Στο Κεφάλαιο 3 γίνεται αναφορά στην Τεχνητή Νοημοσύνη και τον ρόλο της στις βιοϊατρικές εφαρμογές. Εστιάζει σε βασικούς τομείς, όπως η μηχανική μάθηση, τα τεχνητά νευρωνικά δίκτυα, η εξόρυξη δεδομένων (data mining), καθώς και οι πιο συνηθισμένοι αλγόριθμοι ταξινόμησης. Επιπλέον, αναλύονται τα μέτρα αξιολόγησης των μοντέλων τεχνητής νοημοσύνης και ο τρόπος με τον οποίο μπορούν να συμβάλουν στην έγκαιρη διάγνωση και πρόγνωση των ηπατικών παθήσεων.

Στο Κεφάλαιο 4 παρατίθεται μια ανασκόπηση της υπάρχουσας βιβλιογραφίας σχετικά με τη χρήση της Τεχνητής Νοημοσύνης στη διάγνωση και πρόβλεψη ηπατικών διαταραχών. Παρουσιάζονται δεδομένα από προηγούμενες μελέτες, τεχνικές εξόρυξης δεδομένων, αλγόριθμοι μηχανικής μάθησης που έχουν χρησιμοποιηθεί, καθώς και τα ευρήματα που έχουν προκύψει.

Στο Κεφάλαιο 5 παρουσιάζεται η έρευνα που διεξήχθη στο πλαίσιο της παρούσας διπλωματικής εργασίας. Περιγράφονται τα δεδομένα που χρησιμοποιήθηκαν και η διαδικασία προεπεξεργασίας τους.

Στο Κεφάλαιο 6 παρουσιάζονται τα αποτελέσματα της έρευνας και η αξιολόγησή τους. Γίνεται παρουσίαση των αντίστοιχων γραφημάτων και αναλύεται η απόδοση των διαφόρων αλγορίθμων ταξινόμησης στη διάγνωση ηπατικών διαταραχών. Συγκρίνονται τα ευρήματα και εξάγονται συμπεράσματα σχετικά με την αποτελεσματικότητα των μεθόδων που εφαρμόστηκαν.

Στο Κεφάλαιο 7, διατυπώνονται τα συμπεράσματα που απορρέουν από την παρούσα έρευνα.


Στο τέλος της εργασίας παρατίθεται η βιβλιογραφία και το παράρτημα.

Κεφάλαιο 2. Ανάλυση διαταραχών του ήπατος

2.1. Εισαγωγή

Το ήπαρ είναι ένα από τα πιο ζωτικά όργανα του ανθρώπινου σώματος, παίζοντας κεντρικό ρόλο σε πολλές κρίσιμες λειτουργίες που διατηρούν την υγεία και την ισορροπία του οργανισμού. Είναι υπεύθυνο για το μεταβολισμό των θρεπτικών συστατικών, την αποτοξίνωση του αίματος, την παραγωγή πρωτεϊνών και την αποθήκευση ενέργειας με τη μορφή γλυκογόνου. Επιπλέον, το ήπαρ συμβάλλει στη σύνθεση σημαντικών πρωτεϊνών του πλάσματος, όπως η αλβουμίνη και οι παράγοντες πήξης, που είναι απαραίτητοι για την ομοιόσταση. Έχει επίσης βασικό ρόλο στην αποδόμηση φαρμάκων και τοξικών ουσιών, προστατεύοντας έτσι το σώμα από δυνητικά επιβλαβείς ενώσεις. Λόγω της πολυλειτουργικότητάς του, τυχόν βλάβες στο ήπαρ, όπως αυτές που προκαλούνται από ιογενείς λοιμώξεις, υπερβολική κατανάλωση αλκοόλ ή μεταβολικές διαταραχές, μπορεί να έχουν σοβαρές επιπτώσεις στην υγεία. Η σημασία της διατήρησης ενός υγιούς ήπατος είναι αδιαμφισβήτητη, καθώς οποιαδήποτε δυσλειτουργία του μπορεί να οδηγήσει σε ηπατικές ασθένειες, κίρρωση ή ηπατική ανεπάρκεια, γεγονός που υπογραμμίζει την ανάγκη για πρόληψη, έγκαιρη διάγνωση και κατάλληλη θεραπεία.

2.2. Ιστολογία του ήπατος



1. Ηπατική Φλέβα

Ιστολογία: Οι ηπατικές φλέβες είναι μεγάλα αιμοφόρα αγγεία επενδυμένα με απλό πλακώδες επιθήλιο. Τα τοιχώματά τους περιέχουν κολλαγόνες ίνες και μικρή ποσότητα λείου μυός.

Λειτουργία: Συλλέγουν το αποξυγονωμένο αίμα από το ήπαρ και το αποστραγγίζουν στην κάτω κοίλη φλέβα.

2. Σύστημα Κεντρικής Φλέβας

Ιστολογία: Οι κεντρικές φλέβες βρίσκονται εντός των ηπατικών λοβίων και περιβάλλονται από απλό πλακώδες επιθήλιο. Έχουν λεπτό τοίχωμα και αποτελούνται από ενδοθηλιακά κύτταρα.

Λειτουργία: Συγκεντρώνουν αίμα από τα ηπατικά ημιτονοειδή και το κατευθύνουν προς τις ηπατικές φλέβες.

3. Αορτή

Ιστολογία: Η αορτή αποτελείται από τρία στρώματα:

Έσω χιτώνας (tunica intima): Ενδοθήλιο και συνδετικός ιστός.

Μέσος χιτώνας (tunica media): Παχύ στρώμα από ελαστικές ίνες και λείους μυς.

Έξω χιτώνας (tunica adventitia): Ινώδης συνδετικός ιστός.

Λειτουργία: Προμηθεύει οξυγονωμένο αίμα στην ηπατική αρτηρία, η οποία στη συνέχεια θρέφει το ήπαρ.

4. Κλάδος του Χοληδόχου Πόρου

Ιστολογία: Οι χοληφόροι πόροι είναι επενδυμένοι από απλό κυβοειδές ή κυλινδρικό επιθήλιο, ανάλογα με το μέγεθός τους. Ο περιβάλλων συνδετικός ιστός περιέχει κολλαγόνο και λείους μυς.

Λειτουργία: Μεταφέρουν τη χολή από τα ηπατοκύτταρα στη χοληδόχο κύστη και το δωδεκαδάκτυλο για την πέψη.

5. Κλάδος της Ηπατικής Αρτηρίας

Ιστολογία: Η ηπατική αρτηρία έχει παρόμοια δομή με άλλες αρτηρίες και αποτελείται από:

Έσω χιτώνας (ενδοθήλιο)

Μέσος χιτώνας (λείος μυς και ελαστικές ίνες)

Έξω χιτώνας (συνδετικός ιστός)

Λειτουργία: Παρέχει οξυγονωμένο αίμα στα ηπατοκύτταρα.

6. Κλάδος της Πυλαίας Φλέβας

Ιστολογία: Η πυλαία φλέβα έχει λεπτό μέσο χιτώνα με λιγότερους λείους μυς από τις αρτηρίες. Είναι επενδυμένη με ενδοθηλιακά κύτταρα και περιέχει ελαστικές και κολλαγόνες ίνες.

Λειτουργία: Μεταφέρει πλούσιο σε θρεπτικά συστατικά αίμα από το γαστρεντερικό σύστημα στο ήπαρ για μεταβολισμό.

7. Δεξιός και Αριστερός Ηπατικός Πόρος (Χοληφόροι Πόροι)

Ιστολογία: Αυτοί οι πόροι επενδύονται από απλό κυλινδρικό επιθήλιο και περιβάλλονται από ινοελαστικό συνδετικό ιστό και λείους μυς, που διευκολύνουν τη μεταφορά της χολής.

Λειτουργία: Μεταφέρουν τη χολή από το ήπαρ στη χοληδόχο κύστη και το δωδεκαδάκτυλο.

8. Δεξιά και Αριστερή Ηπατική Αρτηρία

Ιστολογία: Αυτές οι αρτηρίες έχουν παχύ μέσο χιτώνα, που περιέχει λείους μυς και ελαστικό ιστό για τη ρύθμιση της ροής του αίματος.

Λειτουργία: Προμηθεύουν τα ηπατοκύτταρα με οξυγονωμένο αίμα.

9. Πυλαία Φλέβα

Ιστολογία: Η πυλαία φλέβα διαθέτει λεπτό μέσο χιτώνα, αποτελούμενο από ενδοθηλιακά κύτταρα, κολλαγόνο και λείους μυς.

Λειτουργία: Μεταφέρει αίμα πλούσιο σε θρεπτικά συστατικά από το πεπτικό σύστημα στο ήπαρ.

10. Πυλαία Τριάδα των Δομών

Ιστολογία: Η πυλαία τριάδα αποτελείται από:

Χοληδόχο πόρο (επενδυμένο με απλό κυβοειδές ή κυλινδρικό επιθήλιο)

Κλάδο της πυλαίας φλέβας (αγγείο με ενδοθηλιακή επένδυση)

Κλάδο της ηπατικής αρτηρίας (αρτηρία με λείους μυς)

Λειτουργία: Διευκολύνει την ανταλλαγή αίματος, χολής και θρεπτικών ουσιών μεταξύ των ηπατοκυττάρων και του κυκλοφορικού συστήματος.

2.3. Φυσιολογία του ήπατος

Το ήπαρ αποτελεί ένα από τα πιο ζωτικής σημασίας όργανα του ανθρώπινου σώματος, επιτελώντας μια πληθώρα βασικών λειτουργιών. Ορισμένες από τις κυριότερες λειτουργίες του περιλαμβάνουν:

1. **Μεταβολισμός:** Συμμετέχει ενεργά στην επεξεργασία των θρεπτικών συστατικών και των φαρμάκων που απορροφώνται από το πεπτικό σύστημα. Επιπλέον, συμβάλλει στη ρύθμιση του μεταβολισμού μετατρέποντας τα τρόφιμα σε ενέργεια και αποθηκεύοντας την πλεονάζουσα ποσότητα ως γλυκογόνο.
2. **Αποτοξίνωση:** Λειτουργεί ως το βασικό όργανο αποτοξίνωσης, εξουδετερώνοντας βλαβερές ουσίες όπως το αλκοόλ, τα φάρμακα και διάφορους μεταβολίτες, ώστε να απομακρύνονται από τον οργανισμό.
3. **Συνθετική δραστηριότητα:** Το ήπαρ παίζει καθοριστικό ρόλο στην παραγωγή ζωτικών ουσιών, όπως η χολή, απαραίτητη για τη διάσπαση των λιπών, οι παράγοντες πήξης του αίματος, καθώς και η αλβουμίνη, μια πρωτεΐνη που συμβάλλει στη ρύθμιση της κατανομής των υγρών στο σώμα.
4. **Αποθήκευση θρεπτικών στοιχείων:** Δρα ως αποθήκη σημαντικών ουσιών, όπως βιταμίνες, μέταλλα και γλυκογόνο, τα οποία απελευθερώνονται στην κυκλοφορία του αίματος όταν υπάρχει ανάγκη.
5. **Ανοσολογική λειτουργία:** Συμμετέχει στην άμυνα του οργανισμού μέσω της παραγωγής ανοσολογικών παραγόντων και της απομάκρυνσης βακτηρίων και ξένων σωματιδίων από το αίμα.


Συνοψίζοντας, το ήπαρ αποτελεί θεμελιώδες όργανο για τη διατήρηση της ομοιόστασης και της γενικής υγείας του ανθρώπινου σώματος, υποστηρίζοντας πολλαπλές κρίσιμες λειτουργίες.

2.4. Κίρρωση ήπατος

Η κίρρωση του ήπατος είναι μια σοβαρή ασθένεια που χαρακτηρίζεται από την αντικατάσταση του φυσιολογικού ηπατικού ιστού από ινώδη ουλώδη ιστό, σχηματίζοντας όζους ηπατικών κυττάρων. Αυτή η χρόνια πάθηση είναι το αποτέλεσμα μακροχρόνιας βλάβης από διάφορους επιβλαβείς παράγοντες και οδηγεί σε προοδευτική μείωση της ηπατικής λειτουργίας, που μπορεί να εξελιχθεί σε σοβαρή ανεπάρκεια και, σε ορισμένες περιπτώσεις, στην ανάπτυξη ηπατοκυτταρικού καρκίνου. Βασικός στόχος είναι η έγκαιρη ανίχνευση ηπατικών διαταραχών που μπορεί να εξελιχθούν σε κίρρωση, με απώτερο σκοπό την αποτελεσματική πρόληψή της.

Στάδια κίρρωσης ήπατος

- ▶ Το πρώτο στάδιο ονομάζεται αντιρροπούμενη κίρρωση, το οποίο θεωρείται αξιόπιστη και ασφαλής μορφή και δεν αποτελεί κρίσιμη κατάσταση για τον ασθενή.
- ▶ Το δεύτερο στάδιο ονομάζεται μη αντιρροπούμενη κίρρωση, θεωρείται κρίσιμο για την υγεία του ασθενή και χρήζει άμεσης αντιμετώπισης.



Παράγοντες που αυξάνουν τον κίνδυνο εμφάνισης κίρρωσης:

- Υπερβολική κατανάλωση αλκοόλ για μεγάλα χρονικά διαστήματα.
- Λιπώδης νόσος του ήπατος, ιδιαίτερα σε άτομα με παχυσαρκία ή σακχαρώδη διαβήτη.
- Λοιμώξεις από τους ιούς της ηπατίτιδας B και C, που μπορούν να προκαλέσουν χρόνια ηπατική βλάβη.

- Αυτοάνοσα νοσήματα του ήπατος, όπου το ανοσοποιητικό σύστημα επιτίθεται στον ηπατικό ιστό.
- Γενετικά νοσήματα που επηρεάζουν το συκώτι, όπως η αιμοχρωμάτωση και η νόσος του Wilson.

Επιπτώσεις της κίρρωσης

Καθώς η ασθένεια εξελίσσεται, η ίνωση που αναπτύσσεται στο ήπαρ διαταράσσει την κανονική ροή του αίματος μέσω της πυλαίας φλέβας, προκαλώντας πυλαία υπέρταση. Αυτό οδηγεί στο σχηματισμό εναλλακτικών φλεβικών οδών, που δημιουργούν τους κίρσους, κυρίως στον οισοφάγο και στο στομάχι, οι οποίοι μπορούν να αιμορραγήσουν επικίνδυνα.

Στα αρχικά στάδια, η κίρρωση είναι αντιρροπούμενη, δηλαδή το ήπαρ εξακολουθεί να εκτελεί τις βασικές του λειτουργίες χωρίς εμφανή συμπτώματα. Ωστόσο, καθώς η νόσος προχωρά και γίνεται μη αντιρροπούμενη, εμφανίζονται σοβαρές επιπλοκές, όπως:

- Αιμορραγία κίρσων, ειδικά στον οισοφάγο, που μπορεί να είναι απειλητική για τη ζωή.
- Ασκίτης, συσσώρευση υγρού στην κοιλιακή χώρα, προκαλώντας έντονο φούσκωμα.
- Ηπατική εγκεφαλοπάθεια, που εκδηλώνεται με διαταραχές μνήμης, σύγχυση και σε προχωρημένα στάδια, κώμα.
- Ίκτερος, που δίνει κιτρινωπή απόχρωση στο δέρμα και στα μάτια λόγω της αδυναμίας του ήπατος να απομακρύνει τη χολερυθρίνη.
- Ανοσολογική και νεφρική δυσλειτουργία, καθώς η ηπατική ανεπάρκεια επηρεάζει και άλλα όργανα.
- Ηπατοκυτταρικός καρκίνος, ένας σοβαρός κίνδυνος για άτομα με προχωρημένη κίρρωση.

Διάγνωση και αντιμετώπιση

Η διάγνωση της κίρρωσης βασίζεται σε κλινική εξέταση, αιματολογικές εξετάσεις, απεικονιστικό έλεγχο (υπερηχογράφημα, αξονική ή μαγνητική τομογραφία) και, σε ορισμένες περιπτώσεις, βιοψία ήπατος. Για την εκτίμηση της σοβαρότητας της νόσου, χρησιμοποιούνται δείκτες όπως το Child-Pugh score και το MELD score, που βοηθούν στον καθορισμό της θεραπευτικής προσέγγισης.

Η θεραπεία στοχεύει:

- Στη σταθεροποίηση ή αναστροφή της βλάβης, εφόσον είναι εφικτό.
- Στην αποφυγή περαιτέρω επιδείνωσης, μέσω διακοπής αλκοόλ, αντιμετώπισης λοιμώξεων ή υποστήριξης της ηπατικής λειτουργίας.
- Στην αντιμετώπιση των επιπλοκών, όπως ο ασκίτης, η εγκεφαλοπάθεια ή οι κίρσοι.

Σε προχωρημένα στάδια, όταν η ηπατική ανεπάρκεια γίνεται μη αναστρέψιμη και απειλητική για τη ζωή, η μεταμόσχευση ήπατος αποτελεί τη μοναδική λύση. Ωστόσο, η διαδικασία είναι πολύπλοκη, απαιτεί εξειδικευμένη προσέγγιση και επηρεάζεται από τη διαθεσιμότητα οργάνων.

Η έγκαιρη διάγνωση και η τροποποίηση του τρόπου ζωής μπορούν να επιβραδύνουν την εξέλιξη της νόσου, βελτιώνοντας την ποιότητα ζωής των ασθενών.

Κεφάλαιο 3. Τεχνητή Νοημοσύνη

3.1. Εισαγωγή

Τα υπολογιστικά συστήματα έχουν αποκτήσει καθοριστικό ρόλο στην καθημερινότητά μας τις τελευταίες δεκαετίες, επηρεάζοντας τόσο τον επαγγελματικό όσο και τον προσωπικό τομέα. Πολλές επιχειρήσεις και δημόσιοι φορείς τα αξιοποιούν για την ανάλυση φαινομένων, την επίλυση προβλημάτων και τη λήψη αποφάσεων μέσω προβλεπτικών μοντέλων και ταξινομήσεων.

Η πολυπλοκότητα των δεδομένων και των ζητημάτων που προκύπτουν σε διάφορους κλάδους έχει καταστήσει αναγκαία την ανάπτυξη ευφύων πληροφοριακών συστημάτων, τα οποία διαθέτουν χαρακτηριστικά παρόμοια με την ανθρώπινη νοημοσύνη.

Η τεχνητή νοημοσύνη (AI) παρουσιάζει αρκετά πλεονεκτήματα σε σχέση με τη φυσική νοημοσύνη, καθώς είναι πιο σταθερή, μπορεί να αναπαραχθεί και να διαδοθεί εύκολα, είναι οικονομικότερη, επιτρέπει την καταγραφή και αποθήκευση δεδομένων και εκτελεί πολύπλοκες διαδικασίες με ταχύτητα και ακρίβεια. Ωστόσο, η ανθρώπινη νοημοσύνη υπερτερεί σε θέματα δημιουργικότητας, συνδυαστικής σκέψης και αξιοποίησης εμπειριών για την προσαρμογή σε νέα δεδομένα.

Ορισμός και Εξέλιξη της Τεχνητής Νοημοσύνης

Ο όρος Τεχνητή Νοημοσύνη (Artificial Intelligence) εισήχθη το 1956 και αναφέρεται στον τομέα της πληροφορικής που επικεντρώνεται στον σχεδιασμό και την ανάπτυξη υπολογιστικών συστημάτων τα οποία προσομοιώνουν ανθρώπινες γνωστικές ικανότητες, όπως η μάθηση, η προσαρμογή, η αναγνώριση προτύπων, η εξαγωγή συμπερασμάτων και η επίλυση προβλημάτων.

Τα συστήματα αυτά έχουν εφαρμογές σε πολλούς τομείς, από τη διαχείριση εναέριας κυκλοφορίας και την ιατρική διάγνωση, έως τις έξυπνες οικιακές συσκευές. Πρόκειται για έναν κλάδο που εξελίσσεται ραγδαία, αξιοποιώντας τεχνικές από τα εφαρμοσμένα μαθηματικά και τις επιστήμες μηχανικής, ενώ η επιρροή της μαθηματικής λογικής και της θεωρητικής πληροφορικής είναι πλέον μικρότερη.

Βασικές Κατηγορίες της Τεχνητής Νοημοσύνης

Η τεχνητή νοημοσύνη διακρίνεται σε δύο κύριες κατηγορίες:

► Κλασική ή Συμβολική Τεχνητή Νοημοσύνη (Symbolic AI)

Εστιάζει στη μίμηση της ανθρώπινης σκέψης μέσω αλγορίθμων και συστημάτων κανόνων.

► Υπολογιστική Νοημοσύνη (Computational Intelligence)

Περιλαμβάνει διάφορες υπολογιστικές προσεγγίσεις που αποσκοπούν στην ενσωμάτωση ευφυών χαρακτηριστικών στις μηχανές.

Στις βασικές τεχνικές περιλαμβάνονται:

- ο Νευρωνικά Δίκτυα (Neural Networks)
- ο Ασαφή Συστήματα (Fuzzy Systems)
- ο Εξελικτικός Υπολογισμός (Optimization)

Σε μεταγενέστερα στάδια αναπτύχθηκαν επίσης:

- ο Αλγόριθμοι Ευφυΐας Σμήνους (Swarm Intelligence)
- ο Μηχανές Διανύσματος Υποστήριξης (Support Vector Machines - SVM)

Επιμέρους Περιοχές της Τεχνητής Νοημοσύνης

Μερικοί σημαντικοί τομείς εφαρμογής της τεχνητής νοημοσύνης περιλαμβάνουν:

- Μηχανική Μάθηση (Machine Learning)
 - ο Επιτρέπει στους υπολογιστές να "μαθαίνουν" από δεδομένα και να βελτιώνουν την απόδοσή τους χωρίς να προγραμματίζονται ρητά.
- Εξόρυξη Δεδομένων (Data Mining)
 - ο Χρησιμοποιεί τεχνικές ΑΙ για την ανάλυση μεγάλων όγκων δεδομένων και την εξαγωγή χρήσιμων πληροφοριών.

3.2. Μηχανική Μάθηση

Η Μηχανική Μάθηση (ML) είναι ένας από τους πιο σημαντικούς κλάδους της Τεχνητής Νοημοσύνης, καθώς επιτρέπει στα συστήματα να αποκτούν νέες γνώσεις και να βελτιώνουν την απόδοσή τους χωρίς να απαιτείται εκ νέου προγραμματισμός. Αντί να δημιουργούνται ρητά μοντέλα, τα συστήματα μαθαίνουν μέσω της επεξεργασίας δεδομένων, αξιοποιώντας προηγούμενες εμπειρίες και γνώσεις.

Στο πλαίσιο της Συμβολικής Τεχνητής Νοημοσύνης (Symbolic AI), η έννοια της "μάθησης" αφορά την απόκτηση επιπλέον γνώσης, η οποία μπορεί είτε να μεταβάλλει, να ενισχύσει ή να μειώσει την υπάρχουσα γνώση. Αντίθετα, στην Υπολογιστική Τεχνητή Νοημοσύνη (Computational Intelligence), η μάθηση δεν τροποποιεί την αποθηκευμένη γνώση, αλλά αλλάζει την εσωτερική δομή του συστήματος ώστε να προσαρμόζεται δυναμικά σε νέα δεδομένα.

Τα τελευταία χρόνια έχουν αναπτυχθεί προηγμένοι αλγόριθμοι μάθησης, οι οποίοι έχουν οδηγήσει στη δημιουργία επιτυχημένων εμπορικών εφαρμογών σε διάφορους τομείς.

Ένα ιδιαίτερο πεδίο της Μηχανικής Μάθησης είναι η Εξελικτική Μάθηση (Evolutionary Learning), η οποία βασίζεται σε γενετικούς αλγορίθμους που μιμούνται τη διαδικασία της φυσικής επιλογής και της αναπαραγωγής στα έμβια όντα. Αυτές οι τεχνικές χρησιμοποιούνται κυρίως για την επίλυση προβλημάτων βελτιστοποίησης προσφέροντας αποτελεσματικές λύσεις σε πολύπλοκα υπολογιστικά προβλήματα.

3.3. Τεχνητά Νευρωνικά Δίκτυα

Ένα Τεχνητό Νευρωνικό Δίκτυο (ANN) είναι ένα υπολογιστικό σύστημα σχεδιασμένο να μιμείται τον τρόπο με τον οποίο ο ανθρώπινος εγκέφαλος επεξεργάζεται και αναλύει πληροφορίες. Αποτελεί βασικό στοιχείο της Τεχνητής Νοημοσύνης (AI) και μπορεί να επιλύει πολύπλοκα προβλήματα που θα ήταν δύσκολο ή αδύνατο να αντιμετωπιστούν με παραδοσιακές μεθόδους ή στατιστικές τεχνικές.

Τα Τεχνητά Νευρωνικά Δίκτυα (ΤΝΔ) ανήκουν στους αλγορίθμους Μηχανικής Μάθησης και είναι εμπνευσμένα από τη βιολογική δομή και λειτουργία του ανθρώπινου εγκεφάλου.

Ιδιότητες και Εκπαίδευση των Τεχνητών Νευρωνικών Δικτύων

Η βασική ικανότητα ενός Τεχνητού Νευρωνικού Δικτύου είναι η μάθηση, η οποία επιτυγχάνεται μέσω εκπαίδευσης. Η διαδικασία εκπαίδευσης πραγματοποιείται επαναληπτικά, προσαρμόζοντας σταδιακά τις παραμέτρους του δικτύου (όπως τα βάρη και τις μετατοπίσεις του) ώστε να επιτυγχάνεται υψηλή ακρίβεια στην επίλυση ενός προβλήματος.

Τα ΤΝΔ εκπαιδεύονται μέσω κατευθυνόμενης Μηχανικής Μάθησης (Supervised Learning), όπου το σύστημα χρησιμοποιεί ένα σύνολο δεδομένων με γνωστές εξόδους για να προσαρμόσει τις εσωτερικές παραμέτρους του.

Ανάλογα με τον τύπο των εξόδων, διακρίνονται σε:

- ΤΝΔ Παλινδρόμησης (Regression Neural Networks): Χρησιμοποιούνται για προβλήματα που απαιτούν προβλέψεις συνεχών τιμών.
- ΤΝΔ Ταξινόμησης (Classification Neural Networks): Αντιμετωπίζουν προβλήματα όπου οι έξοδοι αντιστοιχούν σε κατηγορίες (labels).

Βαθιά Νευρωνικά Δίκτυα (Deep Neural Networks)

Τα Βαθιά Νευρωνικά Δίκτυα είναι μια εξελιγμένη μορφή ΤΝΔ, η οποία αποτελείται από περισσότερα από δύο επίπεδα νευρώνων. Αυτά τα δίκτυα χρησιμοποιούνται σε

πολύπλοκες εφαρμογές Μηχανικής Μάθησης, βασίζονται στην αναπαράσταση δεδομένων (Representation Learning) και απαιτούν υψηλή υπολογιστική ισχύ για την αποτελεσματική λειτουργία τους.

Η Τεχνητή Νοημοσύνη βασίζεται όλο και περισσότερο σε Βαθιά Νευρωνικά Δίκτυα, τα οποία έχουν συμβάλει καθοριστικά σε τομείς όπως η επεξεργασία εικόνας και ήχου, η αυτόνομη οδήγηση και οι συστημικές προβλέψεις σε οικονομικά και επιστημονικά πεδία.

3.4. Βαθιά Μάθηση (Deep Learning)

Η Βαθιά Μάθηση αποτελεί έναν προηγμένο κλάδο της Μηχανικής Μάθησης, ο οποίος χρησιμοποιεί πολλαπλά επίπεδα επεξεργασίας για την εξαγωγή σταδιακά πιο σύνθετων χαρακτηριστικών από τα αρχικά δεδομένα εισόδου.

Για παράδειγμα, στην ανάλυση εικόνων, τα κατώτερα επίπεδα ενός βαθιού νευρωνικού δικτύου μπορούν να ανιχνεύσουν απλά γεωμετρικά στοιχεία, όπως άκρες και γωνίες, ενώ τα ανώτερα επίπεδα είναι σε θέση να αναγνωρίσουν περίπλοκες μορφές και έννοιες, όπως γράμματα, αριθμούς ή ακόμα και πρόσωπα.

Τα Βαθιά Νευρωνικά Δίκτυα είναι ένας τύπος Νευρωνικών Δικτύων που περιλαμβάνει περισσότερα από τέσσερα επίπεδα νευρώνων και αποτελεί τη βάση για πολλές σύγχρονες εφαρμογές Τεχνητής Νοημοσύνης, όπως η επεξεργασία εικόνας, η αναγνώριση φωνής και η φυσική γλώσσα (NLP).

3.5. Εξόρυξη Δεδομένων (Data Mining)

Η Εξόρυξη Δεδομένων (Data Mining) είναι η διαδικασία ανάλυσης μεγάλων όγκων δεδομένων με σκοπό την ανίχνευση ανωμαλιών, την ανακάλυψη προτύπων και τον εντοπισμό συσχετίσεων που μπορούν να χρησιμοποιηθούν για πρόβλεψη και λήψη αποφάσεων.

Μείωση Παραμέτρων & Επιλογή Χαρακτηριστικών

Μια σημαντική διεργασία στην Εξόρυξη Δεδομένων είναι η μείωση των παραμέτρων ή αλλιώς η επιλογή χαρακτηριστικών (Feature Selection – Feature Minimization). Αυτή η τεχνική στοχεύει στην επιλογή ενός μικρότερου, αλλά πιο ουσιώδους συνόλου χαρακτηριστικών, βελτιώνοντας την απόδοση των μοντέλων μηχανικής μάθησης.

Η επιλογή χαρακτηριστικών βοηθά στην:

- Εστίαση στις πιο σημαντικές πληροφορίες, οι οποίες σχετίζονται άμεσα με το πρόβλημα που επιλύεται.

- Απλοποίηση του μοντέλου, μειώνοντας τον «θόρυβο» που προέρχεται από μη σχετικές πληροφορίες.
- Επιτάχυνση της διαδικασίας εκπαίδευσης, καθώς λιγότερα δεδομένα απαιτούν επεξεργασία.
- Αποφυγή υπερπροσαρμογής (Overfitting), που συμβαίνει όταν ένα μοντέλο απομνημονεύει αντί να μαθαίνει.

Η επιλογή χαρακτηριστικών μπορεί να θεωρηθεί ως μια διαδικασία φιλτραρίσματος και μείωσης των εισόδων που χρησιμοποιούνται για την ανάλυση, εξασφαλίζοντας ότι μόνο τα πιο σημαντικά δεδομένα παραμένουν προς επεξεργασία.

Γνωστοί Αλγόριθμοι Μείωσης Παραμέτρων

Ορισμένες από τις πιο δημοφιλείς τεχνικές που χρησιμοποιούνται για την επιλογή χαρακτηριστικών περιλαμβάνουν:

- Information Gain (Πληροφοριακό Κέρδος)
- Correlation Analysis (Ανάλυση Συσχέτισης)
- Ανάλυση Κυρίων Συνιστωσών (Principal Component Analysis - PCA)

Αυτές οι μέθοδοι συμβάλλουν στη βελτιστοποίηση της ακρίβειας και της αποδοτικότητας των αλγορίθμων εξόρυξης δεδομένων, διευκολύνοντας τη λήψη αποφάσεων σε πολύπλοκα συστήματα δεδομένων.

3.6. Ταξινόμηση (Classification)

Η ταξινόμηση αναφέρεται στη διαδικασία ομαδοποίησης στοιχείων ή αντικειμένων με βάση συγκεκριμένα κριτήρια. Πρόκειται για μια συστηματική μέθοδο κατηγοριοποίησης, κατά την οποία κάθε αντικείμενο τοποθετείται σε μία από τις προκαθορισμένες ομάδες. Για παράδειγμα, όταν ένας άνθρωπος αναγνωρίζει πρόσωπα ή αντικείμενα στο περιβάλλον του, στην πραγματικότητα εκτελεί μια νοητική ταξινόμηση, προσδίδοντας αναγνωριστικές ετικέτες σε ό,τι βλέπει γύρω του.

Στην ταξινόμηση δεδομένων, τα αντικείμενα διαχωρίζονται σε διακριτές ομάδες, γνωστές ως κλάσεις. Αν υπάρχουν δύο κλάσεις, τότε πρόκειται για δυαδική ταξινόμηση (Binary Classification), ενώ όταν ο αριθμός των κλάσεων είναι μεγαλύτερος, μιλάμε για ταξινόμηση πολλών κλάσεων (Multi-class Classification).

Οι αλγόριθμοι ταξινόμησης έχουν ως στόχο την αναγνώριση μιας σχέσης μεταξύ των δεδομένων εισόδου και των κατηγοριών στις οποίες αυτά ανήκουν. Ένα σύστημα μηχανικής μάθησης, αφού εκπαιδευτεί κατάλληλα και αποκτήσει τη δυνατότητα

γενίκευσης, μπορεί να προβλέψει την κλάση στην οποία ανήκουν νέα, άγνωστα δεδομένα που συναντά για πρώτη φορά.

► Support Vector Machines (SVM)

Οι Μηχανές Διανυσμάτων Υποστήριξης (SVMs) είναι ισχυροί αλγόριθμοι επιβλεπόμενης μάθησης, οι οποίοι χρησιμοποιούνται για ταξινόμηση και παλινδρόμηση. Λειτουργούν κατασκευάζοντας ένα υπερεπίπεδο (hyperplane) που διαχωρίζει τις κατηγορίες των δεδομένων με τον βέλτιστο δυνατό τρόπο. Ένα από τα κύρια χαρακτηριστικά των SVMs είναι η ικανότητά τους να λειτουργούν αποτελεσματικά ακόμα και σε περιπτώσεις υψηλής διάστασης δεδομένων, καθιστώντας τους ιδανικούς για εφαρμογές όπως η αναγνώριση προτύπων και η επεξεργασία εικόνας.

► Naive Bayes

Ο αλγόριθμος Naive Bayes βασίζεται στο Θεώρημα του Bayes και χρησιμοποιείται κυρίως για προβλήματα ταξινόμησης. Υποθέτει ότι οι μεταβλητές εισόδου είναι ανεξάρτητες μεταξύ τους, γεγονός που, παρόλο που συχνά δεν ισχύει πλήρως στην πράξη, τον καθιστά εξαιρετικά γρήγορο και αποδοτικό για μεγάλες ποσότητες δεδομένων. Χρησιμοποιείται ευρέως σε εφαρμογές όπως η ανίχνευση ανεπιθύμητων μηνυμάτων (spam detection) και η ταξινόμηση κειμένων.

► Δέντρα Απόφασης (Decision Trees)

Τα Δέντρα Απόφασης είναι αλγόριθμοι που χρησιμοποιούνται τόσο για ταξινόμηση όσο και για παλινδρόμηση. Διαχωρίζουν τα δεδομένα μέσω διαδοχικών κανόνων, δημιουργώντας ένα δενδρικό μοντέλο αποφάσεων που είναι εύκολο στην ερμηνεία. Η διαδικασία βασίζεται στη διάσπαση των δεδομένων σε κόμβους, λαμβάνοντας υπόψη μετρικές όπως η εντροπία (entropy) ή η μείωση της αβεβαιότητας (Gini Index). Είναι ιδιαίτερα χρήσιμα σε τομείς όπως η πιστωτική αξιολόγηση και η ιατρική διάγνωση.

► Λογιστική Παλινδρόμηση (Logistic Regression)

Η Λογιστική Παλινδρόμηση είναι ένας στατιστικός αλγόριθμος που χρησιμοποιείται για δυαδική ταξινόμηση, δηλαδή όταν υπάρχουν δύο κατηγορίες εξόδου. Χρησιμοποιεί τη σιγμοειδή συνάρτηση (sigmoid function) για να μετατρέψει τις προβλέψεις σε πιθανότητες και να διαχωρίζει τις κατηγορίες. Αν και απλή, παραμένει ένας από τους πιο αξιόπιστους αλγορίθμους για εφαρμογές όπως η ανίχνευση απάτης και η ιατρική διάγνωση.

► K-Nearest Neighbors (KNN)

Ο αλγόριθμος KNN βασίζεται στην αρχή ότι τα αντικείμενα με παρόμοια χαρακτηριστικά ανήκουν στην ίδια κατηγορία. Για να ταξινομήσει ένα νέο δεδομένο, υπολογίζει την απόσταση του από τα κ πλησιέστερα σημεία και του αποδίδει την κλάση που εμφανίζεται πιο συχνά. Είναι ένας απλός και μη παραμετρικός αλγόριθμος, χρήσιμος σε εφαρμογές όπως η σύσταση προϊόντων και η αναγνώριση μοτίβων.

► Τεχνητά Νευρωνικά Δίκτυα (Artificial Neural Networks)

Τα ANNs αποτελούνται από διασυνδεδεμένους κόμβους (νευρώνες), οι οποίοι εμπνέονται από τη δομή του ανθρώπινου εγκεφάλου. Κάθε νευρώνας λαμβάνει σήματα εισόδου, τα επεξεργάζεται και μεταδίδει το αποτέλεσμα στους επόμενους νευρώνες. Η εκπαίδευσή τους πραγματοποιείται μέσω αλγορίθμων βελτιστοποίησης όπως η οπισθοδιάδοση (backpropagation). Χρησιμοποιούνται ευρέως σε εφαρμογές όπως η επεξεργασία φυσικής γλώσσας, η αναγνώριση εικόνας και η ρομποτική.

► Bagging Ensemble Learning

Το Bagging (Bootstrap Aggregating) είναι μια τεχνική ensemble learning που βελτιώνει την απόδοση των μοντέλων μειώνοντας την διακύμανση (variance) και αποτρέποντας το overfitting. Δημιουργεί πολλαπλά υποσύνολα του αρχικού συνόλου δεδομένων μέσω τυχαίας δειγματοληψίας με επανατοποθέτηση (bootstrapping), εκπαιδεύει ένα μοντέλο σε κάθε υποσύνολο και στη συνέχεια συνδυάζει τις προβλέψεις μέσω μέσης τιμής (για παλινδρόμηση) ή ψηφοφορίας (για ταξινόμηση). Ένα από τα πιο γνωστά παραδείγματα Bagging είναι το Random Forest.

► Boosting Ensemble Learning

Το Boosting είναι μια μέθοδος ensemble learning που στοχεύει στη μείωση της μεροληψίας (bias) και στη βελτίωση της ακρίβειας των προβλέψεων. Σε αντίθεση με το Bagging, το Boosting εκπαιδεύει διαδοχικά μοντέλα, όπου κάθε νέο μοντέλο εστιάζει στα σημεία που τα προηγούμενα δυσκολεύτηκαν να προβλέψουν σωστά. Παραδείγματα Boosting αλγορίθμων περιλαμβάνουν το AdaBoost, Gradient Boosting και XGBoost, που χρησιμοποιούνται ευρέως σε εφαρμογές όπως η ταξινόμηση πελατών και η ανάλυση χρηματοοικονομικών δεδομένων.

3.7. Μέτρα απόδοσης μοντέλου

Για την μέτρηση απόδοσης των αλγορίθμων τα δημοφιλέστερα μέτρα είναι:

(P=θετικά

N=αρνητικά

TP=πλήθος παρατηρήσεων σωστά ταξινομημένων ως θετικά

FP= πλήθος παρατηρήσεων λάθος ταξινομημένων ως θετικά

TN= πλήθος παρατηρήσεων σωστά ταξινομημένων ως αρνητικά

FN=πλήθος παρατηρήσεων λάθος ταξινομημένων ως αρνητικά)


► Confusion Matrix (Πίνακας Σύγχυσης)

Ο πίνακας σύγχυσης είναι μια αναλυτική μέθοδος παρουσίασης της απόδοσης ενός μοντέλου ταξινόμησης, συγκρίνοντας τις πραγματικές τιμές με τις

προβλεπόμενες. Είναι ιδιαίτερα χρήσιμος για την ανάλυση της ποιότητας των προβλέψεων, ειδικά σε περιπτώσεις μη ισορροπημένων δεδομένων.

Περιλαμβάνει τέσσερις βασικές κατηγορίες:

- True Positives (TP)
- True Negatives (TN)
- False Positives (FP)
- False Negatives (FN)



► ROC Curve και AUC (Καμπύλη ROC και Εμβαδόν Κάτω από την Καμπύλη - AUC)

Η Καμπύλη ROC (Receiver Operating Characteristic Curve) είναι ένα γραφικό εργαλείο που απεικονίζει την απόδοση ενός μοντέλου ταξινόμησης, δείχνοντας τη σχέση μεταξύ του True Positive Rate (TPR) και του False Positive Rate (FPR) για διάφορα κατώφλια απόφασης. Το AUC (Area Under Curve) αντιπροσωπεύει το συνολικό εμβαδόν κάτω από την καμπύλη και χρησιμοποιείται για να αξιολογήσει την ικανότητα διάκρισης του μοντέλου.

- True Positive Rate (TPR) ή Recall:

$$TPR = \frac{TP}{TP + FN}$$

- False Positive Rate (FPR):

$$FPR = \frac{FP}{FP + TN}$$

► F1 Score

Το F1 Score είναι ένας συνδυαστικός δείκτης που λαμβάνει υπόψη τόσο την ακρίβεια (Precision) όσο και την ανάκληση (Recall), προσφέροντας μια ισορροπημένη αξιολόγηση της απόδοσης του μοντέλου, ιδιαίτερα σε περιπτώσεις ανισομερούς κατανομής κλάσεων. Είναι ιδιαίτερα χρήσιμο όταν θέλουμε να αποφύγουμε την υπερβολική έμφαση στην ακρίβεια ή στην ανάκληση μεμονωμένα.

$$F1 = 2 \times \frac{Precision \times Recall}{Precision + Recall}$$

► Precision (Ακρίβεια) και Recall (Ανάκληση)

- Η ακρίβεια (Precision) αναφέρεται στο ποσοστό των πραγματικά θετικών προβλέψεων σε σχέση με το σύνολο των θετικών προβλέψεων. Δηλαδή, πόσες από τις προβλεπόμενες θετικές περιπτώσεις είναι πραγματικά σωστές.

$$Precision = \frac{TP}{TP + FP}$$

- Η ανάκληση (Recall) μετρά το ποσοστό των θετικών περιπτώσεων που αναγνωρίστηκαν σωστά από το μοντέλο. Δηλαδή, πόσες από τις πραγματικά θετικές περιπτώσεις ανακτήθηκαν από το μοντέλο.

$$Recall = \frac{TP}{TP + FN}$$

Η σωστή κατανόηση αυτών των μετρικών είναι απαραίτητη για την ανάλυση της αποτελεσματικότητας ενός αλγορίθμου ταξινόμησης, ειδικά σε εφαρμογές όπου η ισορροπία μεταξύ false positives και false negatives είναι κρίσιμη.

Κεφάλαιο 4. Ανασκόπηση βιβλιογραφίας

4.1. Εισαγωγή

Η Τεχνητή Νοημοσύνη έχει βρει εκτεταμένες εφαρμογές τις τελευταίες δεκαετίες σε πολλούς τομείς της ανθρώπινης δραστηριότητας, όπως είναι τα υπολογιστικά παιχνίδια, η αυτόνομη οδήγηση, η πρόβλεψη φυσικών καταστροφών και η παροχή υγειονομικής περίθαλψης. Για την επίτευξη αυτών των στόχων έχουν αναπτυχθεί πολλές κατηγορίες αλγορίθμων μηχανικής μάθησης.

Στον τομέα της υγείας, η Τεχνητή Νοημοσύνη έχει προκαλέσει έντονο ερευνητικό ενδιαφέρον, καθώς αξιοποιείται σε ιατρικές εφαρμογές για τον εντοπισμό ασθενειών, την ανάλυση κινδύνου, την πρόβλεψη και τη λήψη αποφάσεων. Οι ασθένειες που σχετίζονται με υψηλά ποσοστά θνησιμότητας και σημαντικές επιπτώσεις στη δημόσια υγεία, όπως οι ηπατικές διαταραχές, αποτελούν αντικείμενο εντατικής μελέτης.

Οι ηπατικές διαταραχές είναι από τις σοβαρότερες αιτίες νοσηρότητας και θνησιμότητας παγκοσμίως, σύμφωνα με στοιχεία του Παγκόσμιου Οργανισμού Υγείας (ΠΟΥ). Η έγκαιρη ανίχνευση και διάγνωση των ηπατικών διαταραχών είναι ζωτικής σημασίας για τη μείωση του κινδύνου και την αποτελεσματικότερη διαχείρισή τους. Για τον σκοπό αυτό, είναι απαραίτητη η χρήση διαγνωστικών και προληπτικών μεθόδων που συνδυάζουν ακρίβεια και αποτελεσματικότητα.

Η διάγνωση των ηπατικών διαταραχών συχνά απαιτεί βιοψία ή άλλες επεμβατικές διαδικασίες, οι οποίες ενέχουν κινδύνους για τους ασθενείς. Εναλλακτικά, απεικονιστικές τεχνικές μπορεί να χρησιμοποιούνται, αλλά αυτές είναι συνήθως ακριβές και όχι πάντα διαθέσιμες στο ευρύ κοινό. Αυτό δημιουργεί την ανάγκη για ανάπτυξη μη επεμβατικών, οικονομικών, ταχέων αλλά αξιόπιστων τεχνικών διάγνωσης.

Οι αλγόριθμοι μηχανικής μάθησης έχουν αναδειχθεί σε ισχυρό εργαλείο για την ανίχνευση ηπατικών διαταραχών. Το κύριο μέλημα των ερευνητών είναι η ανάπτυξη αξιόπιστων και αποδοτικών μοντέλων τα οποία αξιολογούνται βάσει διάφορων μετρικών. Η απόδοση αυτών των μοντέλων εξαρτάται από την ποιότητα των δεδομένων εκπαίδευσης, την επιλογή χαρακτηριστικών και τη χρήση κατάλληλων μεθόδων μηχανικής μάθησης.

4.2. Αλγόριθμοι επιλογής χαρακτηριστικών και ταξινόμησης παρατηρήσεων

Για την ανίχνευση ηπατικών παθήσεων με τη χρήση αλγορίθμων μηχανικής μάθησης, έχουν εφαρμοστεί διάφορες μέθοδοι επιλογής χαρακτηριστικών που διασφαλίζουν τη βελτιστοποίηση των μοντέλων. Οι πιο κοινές μέθοδοι περιλαμβάνουν:

- Ανάλυση Βασικών Συνιστωσών (Principal Component Analysis - PCA)
- Κέρδος πληροφοριών (Information Gain)
- Συσχέτιση (Correlation)
- Μείωση Διαστάσεων (Dimensionality Reduction)

Αυτές οι μέθοδοι χρησιμοποιούνται για την επιλογή των πιο σημαντικών χαρακτηριστικών από τα σύνολα δεδομένων, συμβάλλοντας στη βελτίωση της ακρίβειας και της αποδοτικότητας των μοντέλων.

Αλγόριθμοι Μηχανικής Μάθησης

Η πλειονότητα των άρθρων στον τομέα αυτό βασίζεται σε αλγορίθμους εποπτευόμενης ταξινόμησης για την ανάλυση δεδομένων και τη λήψη αποφάσεων. Λιγότερο συχνά

χρησιμοποιούνται μέθοδοι μη εποπτευόμενης ομαδοποίησης. Οι πιο συχνά χρησιμοποιούμενοι αλγόριθμοι είναι:

- Τεχνητά Νευρωνικά Δίκτυα (Artificial Neural Networks - ANN)
- Δέντρα Αποφάσεων (Decision Trees)
- Υποστηρικτικές Μηχανές Διανυσμάτων (Support Vector Machines - SVM)

Επιπλέον, χρησιμοποιούνται άλλοι αλγόριθμοι, όπως:

- Naïve Bayes
- K-Nearest Neighbors (KNN)
- Random Forest
- Λογιστική Παλινδρόμηση (Logistic Regression)
- Linear Discriminant Analysis (LDA)
- Boosting Ensemble

Μέτρα Αξιολόγησης Μοντέλων

Για την αξιολόγηση των μοντέλων, το πιο διαδεδομένο μέτρο είναι η ακρίβεια (accuracy), ενώ συχνά συνδυάζεται με άλλες μετρήσεις, όπως:

- Sensitivity (TPR)
- Specificity (TNR)
- Βαθμός απόδοσης (f-score)

Διαχωρισμός Δεδομένων

Η προεπεξεργασία των δεδομένων περιλαμβάνει τη διαίρεση σε σύνολα εκπαίδευσης, δοκιμών και επικύρωσης. Ο πιο συχνά χρησιμοποιούμενος τρόπος είναι η μέθοδος της 10-fold cross-validation, ενώ άλλες διαδεδομένες μέθοδοι περιλαμβάνουν:

- Διαχωρισμό 80%-20% για εκπαίδευση και έλεγχο
- Διαχωρισμό 70%-30%

Η χρήση αυτών των μεθόδων εξασφαλίζει τη σταθερότητα και τη γενίκευση των μοντέλων, ενισχύοντας τη χρησιμότητά τους στην κλινική πρακτική.

4.3. Βιβλιογραφία ανίχνευσης ηπατικών παθήσεων

Η Rajeswari (2010) χρησιμοποιεί δεδομένα από το από το UCI repository, που περιλαμβάνουν 345 περιπτώσεις με 7 χαρακτηριστικά. Η ανάλυση επικεντρώνεται σε αιματολογικές εξετάσεις, οι οποίες διαχωρίζονται σε δύο κατηγορίες: ευαίσθητες και μη ευαίσθητες στις ηπατικές διαταραχές. Το εργαλείο WEKA αξιοποιήθηκε για την ταξινόμηση και αξιολόγηση των δεδομένων με τη μέθοδο του 10-cross validation, εξασφαλίζοντας έτσι την αξιοπιστία των αποτελεσμάτων.

Η διαδικασία περιελάμβανε τη διαίρεση του συνόλου δεδομένων σε 70% εκπαιδευτικά δεδομένα και 30% δοκιμαστικά δεδομένα. Οι αλγόριθμοι Naïve Bayes, FT Tree και Kstar εφαρμόστηκαν για την ταξινόμηση και η απόδοσή τους συγκρίθηκε βάσει ακρίβειας και χρόνου εκτέλεσης. Από τα αποτελέσματα φάνηκε ότι ο αλγόριθμος FT Tree προσέφερε τη μεγαλύτερη ακρίβεια, ενώ απαιτούσε λιγότερο χρόνο εκτέλεσης, γεγονός που τον καθιστά ιδανικό για την ανάλυση αυτού του συνόλου δεδομένων.

Αξίζει να σημειωθεί ότι η μέθοδος αυτή υπογραμμίζει τη σημασία του cross validation και της επιλογής κατάλληλων αλγορίθμων για τη μεγιστοποίηση της ακρίβειας στα μοντέλα πρόβλεψης.

Η Saranya (2017) διεξήγαγε μία ευρεία ανασκόπηση των υφιστάμενων ερευνών για τη διάγνωση των ηπατικών διαταραχών. Η εργασία αυτή περιγράφει τα μεθοδολογικά εργαλεία που χρησιμοποιήθηκαν από προηγούμενους ερευνητές, αναλύει τα πλεονεκτήματα και τα μειονεκτήματα αυτών των μεθόδων και αξιολογεί τους αλγορίθμους με βάση την ταχύτητα, την ακρίβεια, την απόδοση και το κόστος.

Η Saranya ανέλυσε συγκεκριμένα τους αλγορίθμους C4.5 και Support Vector Machines (SVM), επισημαίνοντας ότι ο αλγόριθμος C4.5 ξεχωρίζει λόγω της ικανότητάς του να δημιουργεί εύκολα κατανοητά μοντέλα δέντρων απόφασης. Παρά το γεγονός ότι οι SVM παρουσιάζουν υψηλή ακρίβεια σε ορισμένα σύνολα δεδομένων, η πολυπλοκότητά τους καθιστά τη χρήση τους λιγότερο πρακτική σε μεγάλα δεδομένα.

Η εργασία αυτή προσφέρει σημαντική καθοδήγηση για την επιλογή ταξινομητών που μπορούν να χρησιμοποιηθούν αποτελεσματικά στη διάγνωση ηπατικών παθήσεων.

Η Priya (2018) πρότεινε μία τριφασική προσέγγιση για την κατασκευή μοντέλων ταξινόμησης που προβλέπουν τις ηπατικές παθήσεις. Στην πρώτη φάση, εφαρμόστηκε η κανονικοποίηση min-max στα δεδομένα του UCI, εξασφαλίζοντας την εξάλειψη της πλεονάζουσας πληροφορίας και την ενίσχυση της αξιοπιστίας. Στη δεύτερη φάση, χρησιμοποιήθηκε ο αλγόριθμος επιλογής χαρακτηριστικών PSO (Particle Swarm Optimization) για την εξαγωγή σημαντικών χαρακτηριστικών.

Στην τελική φάση, εφαρμόστηκαν αλγόριθμοι ταξινόμησης όπως Random Forest, SVM, J-48, Multilayer Perceptron και Bayesian Networks. Η ακρίβεια των μοντέλων αξιολογήθηκε με χρήση της ρίζας της μέσης τετραγωνικής τιμής και σφάλματος. Τα αποτελέσματα έδειξαν ότι ο αλγόριθμος J-48 υπερείχε με ακρίβεια 95.04%, καταδεικνύοντας την αποτελεσματικότητά του για την πρόβλεψη ηπατικών ασθενειών.

Η εργασία αυτή υπογραμμίζει τη σημασία της επιλογής χαρακτηριστικών και της κανονικοποίησης για τη βελτίωση της απόδοσης των ταξινομητών.

Ο Ramana (2010) χρησιμοποίησε τον αλγόριθμο Naïve Bayes για τη διάγνωση ηπατικών διαταραχών, αναλύοντας δεδομένα από 751 ασθενείς της πολιτείας Άντρα Πραντές της Ινδίας. Το σύνολο δεδομένων περιελάμβανε 12 χαρακτηριστικά, τα οποία κατατάχθηκαν σε δύο κατηγορίες: ηπατική διαταραχή και μη.

Η ανάλυση έγινε με τη μέθοδο της 10-cross validation, μειώνοντας τη μεροληψία δείγματος. Επιπλέον, πραγματοποιήθηκε επιλογή χαρακτηριστικών με βάση το φύλο και τις ηλικιακές ομάδες, ώστε να εντοπιστούν οι πιο σημαντικοί παράγοντες.

Ο αλγόριθμος Naïve Bayes πέτυχε ακρίβεια 88%, επιβεβαιώνοντας την αποτελεσματικότητά του στη διάγνωση ηπατικών παθήσεων και τονίζοντας τη σημασία της διαχωριστικής ανάλυσης.

Ο Barnaghi (2012) ανέλυσε δεδομένα αιματολογικών εξετάσεων χρησιμοποιώντας διαφορετικές μεθόδους ταξινόμησης, όπως Bayesian Networks, δέντρα απόφασης, νευρωνικά δίκτυα και rough sets. Το σύνολο δεδομένων περιελάμβανε 340 περιπτώσεις με 7 χαρακτηριστικά, και το 66% χρησιμοποιήθηκε για εκπαίδευση και το 34% για δοκιμή.

Οι αλγόριθμοι που εφαρμόστηκαν περιλάμβαναν J48, Logistic Model Tree (LMT), Naïve Bayes, Multilayer Perceptron (MLP) και Radial Basis Function Networks (RBF). Η ανάλυση έδειξε ότι οι αλγόριθμοι J48, MLP και RBF παρουσίασαν την υψηλότερη ακρίβεια. Ειδικότερα, ο MLP υπερείχε με ακρίβεια 91.17% όταν χρησιμοποιήθηκαν έξι χαρακτηριστικά.

Η εργασία αυτή αναδεικνύει τη σημασία της σταδιακής προσθήκης χαρακτηριστικών και της προσαρμογής των αλγορίθμων σε διαφορετικά σύνολα δεδομένων για τη βελτιστοποίηση της ακρίβειας.

Ο Ramana, B. & Venkateswarlu χρησιμοποίησαν την τεχνική ταξινόμησης. Συγκεκριμένα, οι τεχνικές ταξινόμησης που αναλύθηκαν ήταν οι NBTree, Decision

Tree και Naïve Bayes. Στην προτεινόμενη εργασία, εφαρμόστηκε η τεχνική ταξινόμησης Support Vector Machine (SVM) και τα αποτελέσματα συγκρίθηκαν με την ακρίβεια των μοντέλων που παρουσιάστηκαν στην αρχική εργασία. Επιπλέον, χρησιμοποιήθηκε η έκδοση 3.9 του εργαλείου WEKA για την κατασκευή του μοντέλου, ενώ παράλληλα το μοντέλο δημιουργήθηκε και μέσω του Python Jupyter Notebook, προκειμένου να συγκριθούν τα αποτελέσματα και να διαπιστωθεί ποια μέθοδος αποδίδει καλύτερα.

Στόχος της εργασίας ήταν η ανάπτυξη ενός μοντέλου πρόβλεψης ηπατικών παθήσεων. Υπάρχουν πολλοί παράγοντες που συμβάλλουν στην εμφάνιση ηπατικών διαταραχών, και μερικοί από αυτούς είναι καθοριστικοί για τη διάγνωση. Αυτοί περιλαμβάνουν:

- Ολική Χολερυθρίνη (Total Bilirubin): Το σύνολο της χολερυθρίνης που παράγεται από τη διάσπαση παλαιών ερυθρών αιμοσφαιρίων στο σώμα.
- Άμεση Χολερυθρίνη (Direct Bilirubin): Ουσία που δημιουργείται από τη διάσπαση των παλαιών ερυθρών αιμοσφαιρίων και αποτελεί μέρος της χολής που παράγει το ήπαρ για την πέψη.
- Αλκαλική Φωσφατάση (Alkaline Phosphatase): Ένζυμο που λειτουργεί ως καταλύτης για την υποστήριξη της χολής που παράγεται από το ήπαρ.
- Αλανινοτρανσφεράση (Alamine Aminotransferase): Ένζυμο που βρίσκεται κυρίως στο πλάσμα και στο ήπαρ.
- Ασπαρταμινοτρανσφεράση (Aspartate Aminotransferase): Παράγοντας που συμμετέχει στον μεταβολισμό, βοηθώντας στη διατήρηση της υγείας του ήπατος.
- Ολικές Πρωτεΐνες (Total Proteins): Η συνολική συγκέντρωση πρωτεϊνών στο σώμα.
- Αλβουμίνη (Albumin): Μια βασική πρωτεΐνη που συμμετέχει στον υπολογισμό της συνολικής ποσότητας πρωτεΐνης.
- Λόγος Αλβουμίνης προς Σφαιρίνη (Albumin to Globulin Ratio): Ο λόγος μεταξύ των δύο πρωτεϊνών, Αλβουμίνης και Σφαιρίνης, που υπάρχουν στο ανθρώπινο σώμα.

Στον παρακάτω πίνακα παρουσιάζονται οι φυσιολογικές τιμές για κάθε χαρακτηριστικό, κάτι που βοηθά στην απομάκρυνση των ακραίων τιμών από το σύνολο δεδομένων με τη χρήση τεχνικών συσταδοποίησης (clustering) (Vijayakumar, J., 2013; Manchula, A., 2014).

Information (Normal Value)
Age of the patient
Gender of the patient
Total Bilirubin (0.22-1.0 mg/dl)
Direct Bilirubin (0.0-0.2 mg/dl)
Alkaline Phosphatase (110-310 U/L)
Alamine Aminotransferase (5-45 U/L)
Aspartate Aminotransferase (5-40 U/L)
Total Proteins (5.5-8 gm/dl)
Albumin (3.5-5 gm/dl)
Albumin and Globulin Ratio (≥ 1)

Η εργασία αυτή προσφέρει πολύτιμα ευρήματα σχετικά με την ακρίβεια διαφορετικών μοντέλων ταξινόμησης και υπογραμμίζει τη σημασία των χαρακτηριστικών στη δημιουργία αξιόπιστων προβλέψεων για ηπατικές διαταραχές.

Κεφάλαιο 5. Έρευνα

5.1. Εισαγωγή

Στην συγκεκριμένη έρευνα χρησιμοποιήθηκε η Python, η οποία είναι μία από τις πιο δημοφιλείς και ευρέως χρησιμοποιούμενες γλώσσες προγραμματισμού, κυρίως λόγω της ευελιξίας και της διευρυμένης υποστήριξης που προσφέρει μέσω βιβλιοθηκών και εργαλείων. Χρησιμοποιείται εκτενώς σε τομείς όπως η ανάλυση δεδομένων, η μηχανική μάθηση, η τεχνητή νοημοσύνη και η ανάπτυξη εφαρμογών. Στο πλαίσιο της συγκεκριμένης εργασίας, αξιοποιήθηκε ένα σύνολο από βιβλιοθήκες της Python που ενισχύουν τη διαδικασία προεπεξεργασίας, ανάλυσης και δημιουργίας προβλέψεων.

Αρχικά, χρησιμοποιήθηκαν βιβλιοθήκες όπως οι Pandas και Numpy για την ανάγνωση, επεξεργασία και ανάλυση δεδομένων, καθώς και η matplotlib για την οπτικοποίηση αποτελεσμάτων. Στη συνέχεια, εργαλεία όπως το scikit-learn και το imbalanced-learn διευκόλυναν τη χρήση αλγορίθμων μηχανικής μάθησης και την αντιμετώπιση ζητημάτων ανισορροπίας στα δεδομένα μέσω τεχνικών oversampling, όπως το SMOTE.

Επιπλέον, ενσωματώθηκαν τεχνικές μείωσης διαστάσεων, όπως η Ανάλυση Κύριων Συνιστωσών (PCA), και χρησιμοποιήθηκαν διάφοροι ταξινομητές, όπως οι SVM, Logistic Regression, K-Nearest Neighbors, Decision Trees, και Naive Bayes. Για την ενίσχυση της ακρίβειας, αξιοποιήθηκαν μέθοδοι ensemble learning, όπως το XGBoost και το Balanced Bagging Classifier.

Στον τομέα των νευρωνικών δικτύων, η βιβλιοθήκη TensorFlow επέτρεψε την ανάπτυξη και εκπαίδευση ενός απλού αλλά αποδοτικού πολυεπίπεδου νευρωνικού δικτύου. Η ολοκληρωμένη χρήση αυτών των εργαλείων εξασφάλισε τη διαχείριση πολύπλοκων προβλημάτων, καθώς και την αποτελεσματική ανάλυση και πρόβλεψη στα δεδομένα που εξετάστηκαν.

5.2. Δεδομένα

Η κύρια πηγή δεδομένων που χρησιμοποιείται για την έρευνα είναι το Indian Liver Patient Dataset (ILPD), το οποίο είναι διαθέσιμο μέσω του UCI Machine Learning Repository. Το συγκεκριμένο σύνολο δεδομένων περιλαμβάνει πληροφορίες για 583 ασθενείς από το νοσοκομείο του Andhra Pradesh, στην Ινδία, και έχει σχεδιαστεί για την ανάλυση ηπατικών διαταραχών μέσω τεχνικών μηχανικής μάθησης.

Το σύνολο δεδομένων περιλαμβάνει 10 χαρακτηριστικά εισόδου, τα οποία σχετίζονται με κλινικές μετρήσεις που χρησιμοποιούνται ευρέως για την αξιολόγηση της λειτουργίας του ήπατος.

Επιπλέον, το σύνολο δεδομένων περιέχει μία διωνυμική μεταβλητή που δηλώνει εάν ένας ασθενής πάσχει ή όχι από ηπατική ασθένεια (Binary Classification). Από τους 583 ασθενείς, οι 416 έχουν διαγνωστεί με ηπατική ασθένεια, ενώ οι 167 δεν πάσχουν, δημιουργώντας έτσι μια ανισομερής κατανομή στις κατηγορίες στόχου.

Η χρήση του ILPD έχει ευρεία αποδοχή στην επιστημονική κοινότητα, καθώς παρέχει υψηλής ποιότητας δεδομένα για την εκπαίδευση και αξιολόγηση μοντέλων μηχανικής μάθησης. Ωστόσο, η ανισορροπία στα δεδομένα καθιστά απαραίτητη την εφαρμογή τεχνικών όπως το oversampling για τη βελτίωση της ακρίβειας των προβλέψεων. Αποτελεί ένα σημαντικό εργαλείο για την ανάπτυξη και τη δοκιμή συστημάτων πρόβλεψης, ενισχύοντας την κατανόηση και τη διαχείριση των ηπατικών ασθενειών.

5.3. Περιγραφή των χαρακτηριστικών

Τα χαρακτηριστικά έχουν ομαδοποιηθεί σε δέκα κατηγορίες και είναι τα κάτωθι:

1. Ηλικία (Age)

Η ηλικία αποτελεί έναν κρίσιμο δημογραφικό παράγοντα που συνδέεται με την υγεία του ήπατος. Οι ηλικιωμένοι ασθενείς έχουν αυξημένη πιθανότητα εμφάνισης ηπατικών ασθενειών, λόγω παραγόντων όπως η χρόνια χρήση φαρμάκων, οι διατροφικές συνήθειες και οι συνοδές παθήσεις. Η ενσωμάτωση της ηλικίας στα δεδομένα ενισχύει τη δυνατότητα των μοντέλων να αναγνωρίζουν τάσεις που σχετίζονται με συγκεκριμένες ηλικιακές ομάδες.

2. Φύλο (Gender)

Το φύλο επηρεάζει άμεσα τη φυσιολογία του ήπατος και τον κίνδυνο ανάπτυξης ηπατικών διαταραχών. Για παράδειγμα, οι άνδρες παρουσιάζουν συχνά μεγαλύτερο κίνδυνο για ασθένειες που σχετίζονται με τη χρήση αλκοόλ, ενώ οι γυναίκες είναι πιο ευάλωτες σε συγκεκριμένες αυτοάνοσες ηπατικές παθήσεις. Η ενσωμάτωση αυτής της μεταβλητής βοηθά στη δημιουργία πιο ακριβών προγνωστικών μοντέλων.

3. Ολική Χολερυθρίνη (Total Bilirubin)

Η ολική χολερυθρίνη μετρά τη συνολική συγκέντρωση χολερυθρίνης στο αίμα. Η αύξηση των επιπέδων της μπορεί να υποδηλώνει δυσλειτουργία του ήπατος ή των χοληφόρων, καθιστώντας τη έναν από τους πιο σημαντικούς δείκτες για την αξιολόγηση της λειτουργίας του ήπατος.

4. Άμεση Χολερυθρίνη (Direct Bilirubin)

Η άμεση χολερυθρίνη σχετίζεται με την ικανότητα του ήπατος να μεταβολίζει τη χολερυθρίνη και να την αποβάλλει μέσω της χολής. Οι αυξημένες τιμές μπορεί να δείχνουν απόφραξη των χοληφόρων ή ηπατοκυτταρική δυσλειτουργία.

5. Αλκαλική Φωσφατάση (Alkaline Phosphatase - ALP)

Η αλκαλική φωσφατάση είναι ένζυμο που σχετίζεται με τη λειτουργία των χοληφόρων. Τα αυξημένα επίπεδα της ενδέχεται να υποδηλώνουν απόφραξη ή βλάβη στους χοληφόρους πόρους.

6. Αλανίνη Αμινοτρανσφεράση (Alanine Aminotransferase - ALT)

Το ALT είναι ένζυμο που απελευθερώνεται στο αίμα κατά τη διάρκεια ηπατικής βλάβης. Είναι ευρέως χρησιμοποιούμενος δείκτης σε περιπτώσεις ηπατίτιδας και λιπώδους ηπατικής νόσου.

7. Ασπαρτική Αμινοτρανσφεράση (Aspartate Aminotransferase - AST)

Το AST αποτελεί ένζυμο που εντοπίζεται όχι μόνο στο ήπαρ αλλά και στην καρδιά και στους μυς. Η αναλογία ALT προς AST βοηθά στη διάκριση μεταξύ αλκοολικής ηπατικής βλάβης και άλλων αιτιών.

8. Ολικές Πρωτεΐνες (Total Proteins)

Οι ολικές πρωτεΐνες αντικατοπτρίζουν τη συνθετική λειτουργία του ήπατος. Μειωμένες τιμές μπορεί να υποδηλώνουν ηπατική ανεπάρκεια ή διαταραχές στον μεταβολισμό των πρωτεϊνών.

9. Λευκωματίνη (Albumin)

Η λευκωματίνη είναι βασική πρωτεΐνη που παράγεται από το ήπαρ. Τα μειωμένα επίπεδά της σχετίζονται με σοβαρή ηπατική ανεπάρκεια ή χρόνια ηπατοπάθεια.

10. Λόγος Λευκωματίνης προς Σφαιρίνη (Albumin/Globulin Ratio)

Η αναλογία λευκωματίνης προς σφαιρίνη αποτελεί έναν χρήσιμο δείκτη για την αξιολόγηση της ισορροπίας των πρωτεϊνών στον οργανισμό. Παθολογικές τιμές μπορεί να υποδηλώνουν φλεγμονώδεις καταστάσεις ή ηπατική ανεπάρκεια.

5.4. Προ επεξεργασία δεδομένων στο excel

- Μετατρέπουμε το αρχείο από csv σε excel.
- Το αρχείο δεδομένων περιέχει μόνο τρεις ελλειπείς τιμές στην μεταβλητή A/G ratio

τις οποίες αφαιρούμε και έτσι έχουμε 580 γραμμές από τις αρχικές 583.

- Κάνουμε μετατροπή του φύλου έτσι ώστε όλες οι μεταβλητές μας να είναι αριθμητικές, ως εξής: όπου female αντικαθιστούμε την τιμή 0 και όπου male την τιμή 1.

5.3. Προεπεξεργασία δεδομένων στην python

Η προεπεξεργασία των δεδομένων είναι ένα κρίσιμο βήμα για τη διασφάλιση της ποιότητας και της ακρίβειας των μοντέλων μηχανικής μάθησης. Τα στάδια προεπεξεργασίας που χρησιμοποιήθηκαν περιλαμβάνουν τις εξής διαδικασίες:

1. Εντοπισμός και Αφαίρεση Ακραίων Τιμών (Outliers)

Το πρώτο βήμα της προεπεξεργασίας αφορά τον εντοπισμό ακραίων τιμών σε κάθε χαρακτηριστικό. Αυτό επιτυγχάνεται μέσω της μεθόδου z-score, όπου οι τιμές που υπερβαίνουν το όριο του 3 θεωρούνται ακραίες. Οι παρατηρήσεις που περιλαμβάνουν ακραίες τιμές αφαιρούνται για να εξασφαλιστεί ότι τα δεδομένα δεν θα επηρεαστούν δυσανάλογα από ανωμαλίες, μειώνοντας έτσι την πιθανότητα υπερεκπαίδευσης (overfitting).

2. Κλιμάκωση Δεδομένων (Standardization)

Μετά τον καθαρισμό των δεδομένων, εφαρμόζεται η μέθοδος StandardScaler της βιβλιοθήκης sklearn για την κλιμάκωση των χαρακτηριστικών. Η κανονικοποίηση (standardization) είναι απαραίτητη για να διασφαλιστεί ότι όλα τα χαρακτηριστικά έχουν συγκρίσιμες τιμές, ειδικά όταν οι διαστάσεις τους διαφέρουν. Αυτή η διαδικασία αποτρέπει την κυριαρχία χαρακτηριστικών με μεγάλες αριθμητικές τιμές έναντι άλλων.

3. Μείωση Διαστάσεων (Dimensionality Reduction)

Η Ανάλυση Κύριων Συνιστωσών (PCA) χρησιμοποιείται για τη μείωση των διαστάσεων των δεδομένων. Το PCA μειώνει τον αριθμό των χαρακτηριστικών, διατηρώντας παράλληλα το 90% της συνολικής πληροφορίας (όπως ορίζεται από τη διατήρηση της διακύμανσης). Αυτή η τεχνική όχι μόνο βελτιώνει την απόδοση των μοντέλων, αλλά και μειώνει το υπολογιστικό κόστος.

4. Αντιμετώπιση Ανισορροπίας Δεδομένων (Imbalanced Data Handling)

Στα δεδομένα, η κατανομή των κατηγοριών στόχου είναι άνιση, κάτι που μπορεί να οδηγήσει σε προκατάληψη του μοντέλου υπέρ της κυρίαρχης κατηγορίας. Για να αντιμετωπιστεί αυτό, χρησιμοποιείται η τεχνική SMOTE (Synthetic Minority Oversampling Technique). Το SMOTE δημιουργεί συνθετικά δείγματα για την μειονεκτική κατηγορία, βελτιώνοντας έτσι τη συνολική ισορροπία του συνόλου δεδομένων.

5. Διαχωρισμός Εκπαιδευτικών και Δοκιμαστικών Συνόλων (Train-Test Split)

Μετά την ολοκλήρωση της επεξεργασίας, τα δεδομένα διαχωρίζονται σε εκπαιδευτικό και δοκιμαστικό σύνολο. Η μέθοδος `train_test_split` της `sklearn` χρησιμοποιείται για τη διαίρεση των δεδομένων σε αναλογία 80/20, εξασφαλίζοντας ότι και οι δύο κατηγορίες εκπροσωπούνται επαρκώς (`stratified split`). Το τυχαίο στοιχείο (`random seed`) σταθεροποιείται για αναπαραγωγικότητα των αποτελεσμάτων.

Κεφάλαιο 6. Αποτελέσματα της έρευνας

6.1. Εισαγωγή

Το παρόν κεφάλαιο παρουσιάζει τα αποτελέσματα της μελέτης που αφορά την πρόβλεψη ηπατικών νοσημάτων με τη χρήση μεθόδων μηχανικής μάθησης. Τα δεδομένα που χρησιμοποιήθηκαν προέρχονται από καταγεγραμμένα ιατρικά ιστορικά και περιλαμβάνουν πληθώρα χαρακτηριστικών που σχετίζονται με τις λειτουργίες του ήπατος. Η ακριβής και έγκαιρη διάγνωση των ηπατικών διαταραχών καθίσταται ζωτικής σημασίας, δεδομένου ότι παθήσεις όπως η κίρρωση, η ηπατίτιδα και η λιπώδης διήθηση του ήπατος ενδέχεται να οδηγήσουν σε σοβαρές επιπλοκές, όπως ηπατική ανεπάρκεια και καρκίνος του ήπατος.

Στόχος της παρούσας εργασίας είναι η ανάπτυξη και αξιολόγηση μοντέλων πρόβλεψης που βασίζονται σε τεχνικές κατηγοριοποίησης. Η ανάλυση επικεντρώνεται στη διερεύνηση της αποδοτικότητας της μεθοδολογίας, αξιοποιώντας αποτελέσματα από βιοχημικές εξετάσεις ήπατος (Liver Function Tests - LFTs), όπως τα επίπεδα της ολικής και άμεσης χολερυθρίνης, των τρανσαμινασών και της λευκωματίνης. Μέσω αυτής της διαδικασίας επιδιώκεται η βελτίωση της διαγνωστικής ακρίβειας και η υποβοήθηση των ιατρών στην έγκαιρη αναγνώριση ηπατικών νοσημάτων, συμβάλλοντας ουσιαστικά στη βελτίωση της παρεχόμενης ιατρικής φροντίδας.



6.2. Αποτελέσματα μετρικών των μοντέλων

Στον παρακάτω πίνακα δίνονται οι μετρικές για το κάθε ένα από τα μοντέλα μηχανικής μάθησης, όπως υπολογιστήκαν από τον κώδικα με τη χρήση της Python.

Model	Precision (class 1)	Recall (class 1)	Precision (class 2)	Recall (class 2)	F1 score (weighted)	AUC- ROC
SVM	0.77	0.80	0.67	0.62	0.73	0.8215
Logistic Regression	0.76	0.84	0.70	0.58	0.73	0.8297
KNN	0.84	0.72	0.64	0.79	0.75	0.8305
Decision Tree	0.87	0.65	0.61	0.85	0.73	0.7584
Naïve Bayes	0.90	0.61	0.60	0.90	0.72	0.7981
Neural Networks	0.91	0.70	0.66	0.90	0.78	0.8395
Boosting Ensemble	0.79	0.81	0.70	0.67	0.75	0.8184
Bagging Ensemble	0.78	0.81	0.69	0.65	0.74	0.8064

6.3. Παρουσίαση γραφημάτων



Στη συνέχεια παρουσιάζονται τα γραφήματα για το κάθε μοντέλο ξεχωριστά όπως υπολογίστηκαν στην Python.



F1 Score (weighted): 0.73

Class 1:
Precision: 0.77
Recall: 0.80



Class 2:
Precision: 0.67
Recall: 0.62



F1 Score (weighted): 0.73

Class 1:
Precision: 0.76
Recall: 0.84



Class 2:
Precision: 0.70
Recall: 0.58



F1 Score (weighted): 0.75

Class 1:
Precision: 0.84
Recall: 0.72



Class 2:
Precision: 0.64
Recall: 0.79



F1 Score (weighted): 0.73

Class 1:
Precision: 0.87
Recall: 0.65



Class 2:
Precision: 0.61
Recall: 0.85



F1 Score (weighted): 0.72

Class 1:
Precision: 0.90
Recall: 0.61



Class 2:
Precision: 0.60
Recall: 0.90



F1 Score (weighted): 0.78

Class 1:
Precision: 0.91
Recall: 0.70



Class 2:
Precision: 0.66
Recall: 0.90



F1 Score (weighted): 0.75

Class 1:
Precision: 0.79
Recall: 0.81

Class 2:
Precision: 0.70
Recall: 0.67



F1 Score (weighted): 0.74

Class 1:
Precision: 0.78
Recall: 0.81

Class 2:
Precision: 0.69
Recall: 0.65

6.3.2. Ανάλυση απόδοσης μοντέλων

Η αξιολόγηση των μοντέλων μηχανικής μάθησης είναι κρίσιμη για τον προσδιορισμό της αποτελεσματικότητάς τους σε classification tasks. Η παρούσα ανάλυση εξετάζει την απόδοση οκτώ μοντέλων: Support Vector Machine (SVM), Logistic Regression, K-Nearest Neighbors (KNN), Decision Tree, Naïve Bayes, Neural Networks, Boosting Ensemble και Bagging Ensemble, βασισμένη σε πολλαπλές μετρικές, όπως ακρίβεια, ανάκληση, F1-score και AUC-ROC καμπύλη.

1. Support Vector Machine (SVM)

Το μοντέλο SVM επιτυγχάνει ακρίβεια 0.77 και ανάκληση 0.80 για την κλάση 1, υποδεικνύοντας μια ισορροπημένη σχέση μεταξύ ψευδώς θετικών και ψευδώς αρνητικών. Ωστόσο, για την κλάση 2, η ακρίβεια (0.67) και η ανάκληση (0.62) είναι χαμηλότερες, υποδηλώνοντας ασθενέστερη προβλεπτική ικανότητα για αυτήν την κατηγορία. Η σταθμισμένη F1-score 0.73 δείχνει μέτρια αποτελεσματικότητα. Με AUC-ROC 0.8215, το SVM παρουσιάζει ισχυρή διακριτική ικανότητα μεταξύ των κλάσεων.

2. Logistic Regression

Το Logistic Regression εμφανίζει παρόμοια σταθμισμένη F1-score (0.73) με το SVM, με ελαφρώς υψηλότερη ανάκληση για την κλάση 1 (0.84) αλλά χαμηλότερη για την κλάση 2 (0.58). Οι τιμές ακρίβειας (0.76 για την κλάση 1 και 0.70 για την κλάση 2) δείχνουν ότι αποδίδει ελαφρώς καλύτερα στην αναγνώριση των περιπτώσεων της κλάσης 2. Η βαθμολογία AUC-ROC 0.8297 υποδηλώνει ισχυρή απόδοση στη διάκριση των κλάσεων.

3. K-Nearest Neighbors (KNN)

Το KNN επιτυγχάνει πολύ καλή ακρίβεια για την κλάση 1 (0.84), αλλά έχει χαμηλότερη ανάκληση (0.72). Για την κλάση 2, η ανάκληση είναι σχετικά υψηλή (0.79), αντισταθμίζοντας μια ελαφρώς χαμηλότερη ακρίβεια (0.64). Η σταθμισμένη F1-score (0.75) είναι αρκετά υψηλή, ενώ η AUC-ROC (0.8305) είναι η δεύτερη καλύτερη μεταξύ των αξιολογημένων μοντέλων.

4. Decision Tree

Το Decision Tree επιδεικνύει υψηλή ακρίβεια για την κλάση 1 (0.87), αλλά με κόστος χαμηλής ανάκλησης (0.65), που υποδηλώνει τάση προς ψευδώς αρνητικά. Αντίθετα, η κλάση 2 εμφανίζει χαμηλότερη ακρίβεια (0.61) αλλά πολύ υψηλότερη ανάκληση (0.85). Η σταθμισμένη F1-score (0.73) είναι αντίστοιχη του SVM και του Logistic Regression, αλλά η AUC-ROC (0.7584) είναι η χαμηλότερη μεταξύ όλων των μοντέλων, δείχνοντας ασθενέστερη συνολική ικανότητα ταξινόμησης.

5. Naïve Bayes

Το Naïve Bayes εμφανίζει την υψηλότερη ακρίβεια για την κλάση 1 (0.90), αλλά τη χαμηλότερη ανάκληση (0.61), που σημαίνει ότι είναι υπερβολικά αυστηρό στις προβλέψεις αυτής της κατηγορίας. Αντίθετα, η κλάση 2 έχει την υψηλότερη ανάκληση (0.90) αλλά τη χαμηλότερη ακρίβεια (0.60). Η σταθμισμένη F1-score (0.72) είναι ελαφρώς χαμηλότερη από άλλα μοντέλα, ενώ η AUC-ROC (0.7981) υποδηλώνει μέτρια αποτελεσματικότητα.

6. Neural Networks

Τα Neural Networks επιτυγχάνουν την υψηλότερη σταθμισμένη F1-score (0.78) και AUC-ROC (0.8395), υπερβαίνοντας όλα τα άλλα μοντέλα στη συνολική ικανότητα ταξινόμησης. Ο δείκτης ανάκλησης για την κλάση 2 (0.90) είναι ιδιαίτερα ισχυρός, ενώ η ακρίβεια (0.66) παραμένει σε λογικά επίπεδα. Παρομοίως, η ακρίβεια για την κλάση 1 (0.91) είναι η υψηλότερη μεταξύ όλων των μοντέλων, αν και η ανάκληση είναι ελαφρώς χαμηλότερη (0.70).

7. Boosting Ensemble

Το Boosting Ensemble διατηρεί μια ισορροπία μεταξύ ακρίβειας και ανάκλησης, με τιμές 0.79 και 0.81 για την κλάση 1, αντίστοιχα. Για την κλάση 2, η ακρίβεια (0.70) και η ανάκληση (0.67) είναι μέτρια αποτελεσματικές. Η σταθμισμένη F1-score (0.75) είναι αντίστοιχη του KNN, ενώ η AUC-ROC (0.8184) υποδηλώνει ισχυρή συνολική ταξινόμηση.

8. Bagging Ensemble

Το Bagging Ensemble εμφανίζει παρόμοιες τιμές ανάκλησης (0.81 για την κλάση 1 και 0.65 για την κλάση 2), υποδηλώνοντας την ικανότητά του να αναγνωρίζει σωστά περιπτώσεις της κλάσης 1. Οι τιμές ακρίβειας (0.78 για την κλάση 1 και 0.69 για την κλάση 2) είναι ελαφρώς χαμηλότερες από το Boosting. Με σταθμισμένη F1-score 0.74 και AUC-ROC 0.8064, το Bagging αποδίδει ανταγωνιστικά, αλλά δεν ξεπερνά το Boosting ή τα Neural Networks.

Μεταξύ των αξιολογημένων μοντέλων, τα Neural Networks εμφανίζουν την πιο ισορροπημένη απόδοση, επιτυγχάνοντας το υψηλότερο AUC-ROC (0.8395). Τα KNN και Boosting επίσης αποδίδουν ανταγωνιστικά. Η επιλογή του βέλτιστου μοντέλου εξαρτάται από τη συγκεκριμένη εφαρμογή, με τα Neural Networks να αναδεικνύονται ως η πιο υποσχόμενη επιλογή.

Κεφάλαιο 7. Σύνοψη και συμπεράσματα

Σύνοψη

Η έγκαιρη και ακριβής διάγνωση των ηπατικών νοσημάτων αποτελεί παράγοντα ζωτικής σημασίας για τη βελτίωση της υγειονομικής περίθαλψης και τη μείωση των επιπλοκών που προκύπτουν από ασθένειες όπως η κίρρωση, η ηπατίτιδα και η λιπώδης διήθηση του ήπατος. Στο πλαίσιο της παρούσας μελέτης, εξετάζεται η αποτελεσματικότητα διαφορετικών μοντέλων μηχανικής μάθησης στην πρόβλεψη ηπατικών διαταραχών, αξιοποιώντας ιατρικά δεδομένα και συγκεκριμένες βιοχημικές εξετάσεις ήπατος. Τα δεδομένα που χρησιμοποιήθηκαν περιλαμβάνουν βασικούς δείκτες όπως τα επίπεδα χολερυθρίνης, τρανσαμινασών και λευκωματίνης, τα οποία συσχετίζονται άμεσα με την ηπατική λειτουργία.

Για την υλοποίηση της μελέτης, αναπτύχθηκαν και αξιολογήθηκαν οκτώ διαφορετικά μοντέλα ταξινόμησης: Support Vector Machine (SVM), Logistic Regression, K-Nearest Neighbors (KNN), Decision Tree, Naïve Bayes, Neural Networks, Boosting Ensemble και Bagging Ensemble. Η απόδοση αυτών των μοντέλων μετρήθηκε μέσω των κριτηρίων ακρίβειας, ανάκλησης, F1-score και AUC-ROC, που αποτελούν θεμελιώδεις δείκτες για την αξιολόγηση της ικανότητάς τους να ταξινομούν με ακρίβεια τα δεδομένα των ασθενών.

Τα αποτελέσματα κατέδειξαν ότι τα Neural Networks (Τεχνητά Νευρωνικά Δίκτυα) ξεχώρισαν ως το πιο αποδοτικό μοντέλο, παρουσιάζοντας το υψηλότερο AUC-ROC (0.8395), γεγονός που υποδηλώνει υψηλή διακριτική ικανότητα μεταξύ των κλάσεων ασθενών. Επιπλέον, το KNN και το Boosting Ensemble παρουσίασαν ανταγωνιστικές επιδόσεις, με υψηλά επίπεδα ακρίβειας και ισορροπημένες τιμές ανάκλησης και F1-score. Αντίθετα, τα μοντέλα Decision Tree και Naïve Bayes εμφάνισαν χαμηλότερες επιδόσεις, γεγονός που ενδεχομένως οφείλεται στη χαμηλή γενίκευσή τους και στη μεγαλύτερη ευαισθησία τους σε αδόμητα δεδομένα.

Η μελέτη καταδεικνύει ότι η χρήση προηγμένων τεχνικών μηχανικής μάθησης μπορεί να συμβάλει στη βελτίωση της διαγνωστικής ακρίβειας ηπατικών παθήσεων, υποστηρίζοντας τους ιατρούς στη λήψη αποφάσεων και ενισχύοντας τη δυνατότητα έγκαιρης παρέμβασης. Παράλληλα, η συγκριτική ανάλυση των αλγορίθμων παρέχει χρήσιμες πληροφορίες για την επιλογή του βέλτιστου μοντέλου, ανάλογα με τις ανάγκες της εκάστοτε ιατρικής εφαρμογής.

Συμπεράσματα και Προοπτικές

Η παρούσα μελέτη ανέδειξε την αξία της μηχανικής μάθησης στην ιατρική διάγνωση, ειδικά στον τομέα της πρόβλεψης ηπατικών νοσημάτων. Μέσω της αξιολόγησης διάφορων αλγορίθμων ταξινόμησης, διαπιστώθηκε όπως είδαμε ότι τα Νευρωνικά Δίκτυα προσφέρουν την υψηλότερη απόδοση, τόσο σε επίπεδο ακρίβειας όσο και σε επίπεδο γενίκευσης των αποτελεσμάτων. Η ικανότητά τους να ανιχνεύουν μοτίβα σε σύνθετα και πολυδιάστατα ιατρικά δεδομένα επιβεβαιώνει τη δυναμική τους ως εργαλείο υποστήριξης στη διάγνωση ηπατικών παθήσεων.

Εντούτοις, τα υπόλοιπα μοντέλα παρουσίασαν διαφορετικές επιδόσεις, επισημαίνοντας τη σημασία της επιλογής της κατάλληλης μεθοδολογίας για κάθε εφαρμογή. Για παράδειγμα, το KNN εμφάνισε ισορροπημένη απόδοση σε επίπεδο ακρίβειας και ανάκλησης, καθιστώντας το αξιόπιστη εναλλακτική λύση, ενώ το Boosting Ensemble απέδειξε την αποτελεσματικότητά του στη βελτίωση της ταξινόμησης μέσω συνδυασμού διαφορετικών μοντέλων. Αντίθετα, το Naïve Bayes και το Decision Tree εμφάνισαν περιορισμούς, λόγω υπεραπλουστευμένων υποθέσεων και μειωμένης προσαρμοστικότητας σε πολύπλοκα δεδομένα.

Παρά τα ενθαρρυντικά αποτελέσματα, η μελέτη αφήνει περιθώρια περαιτέρω βελτιστοποίησης και έρευνας. Οι εξής κατευθύνσεις προτείνονται για μελλοντικές επεκτάσεις:

1. Βελτίωση της ποιότητας των δεδομένων
Η ακρίβεια των μοντέλων εξαρτάται από την ποιότητα και την πληρότητα των δεδομένων. Η ενσωμάτωση μεγαλύτερου αριθμού δεικτών, καθώς και η χρήση πιο ολοκληρωμένων ιατρικών ιστορικών, μπορεί να ενισχύσει την προβλεπτική ικανότητα των μοντέλων.
2. Χρήση υβριδικών προσεγγίσεων
Ο συνδυασμός διαφορετικών τεχνικών μηχανικής μάθησης, όπως υβριδικά μοντέλα που συνδυάζουν νευρωνικά δίκτυα με μεθόδους ενισχυτικής μάθησης, μπορεί να οδηγήσει σε καλύτερη απόδοση και μεγαλύτερη αξιοπιστία στις διαγνώσεις.
3. Εφαρμογή σε πραγματικά κλινικά δεδομένα
Τα παρόντα αποτελέσματα βασίζονται σε δεδομένα από ιατρικά ιστορικά. Ωστόσο, η αξιολόγηση αυτών των μοντέλων σε πραγματικά κλινικά περιβάλλοντα μπορεί να αποκαλύψει νέες προκλήσεις και να επιβεβαιώσει τη χρησιμότητά τους στην καθημερινή ιατρική πρακτική.
4. Ερμηνευσιμότητα των αποτελεσμάτων
Η ιατρική κοινότητα συχνά απαιτεί μοντέλα που είναι όχι μόνο ακριβή αλλά και ερμηνεύσιμα. Η ανάπτυξη τεχνικών Explainable AI (XAI) θα μπορούσε να ενισχύσει την εμπιστοσύνη των ιατρών στη χρήση της μηχανικής μάθησης για διαγνωστικούς σκοπούς.
5. Εξατομικευμένη ιατρική και προγνωστική ανάλυση
Η προσαρμογή των μοντέλων σε εξατομικευμένα ιατρικά προφίλ μπορεί να επιτρέψει την ανάπτυξη συστημάτων που όχι μόνο διαγιγνώσκουν αλλά και προβλέπουν την πορεία της νόσου με μεγαλύτερη ακρίβεια.

Η μελέτη αυτή αποδεικνύει τη σημασία της μηχανικής μάθησης στη διάγνωση ηπατικών νοσημάτων, υποδεικνύοντας ότι τα Τεχνητά Νευρωνικά Δίκτυα αποτελούν την πλέον αποδοτική προσέγγιση. Ωστόσο, η τελική επιλογή του μοντέλου εξαρτάται από τις απαιτήσεις κάθε εφαρμογής, με παραμέτρους όπως η επεξηγησιμότητα, η ακρίβεια και η δυνατότητα γενίκευσης να διαδραματίζουν καθοριστικό ρόλο. Η συνεχής έρευνα στον τομέα αυτό είναι απαραίτητη για τη βελτιστοποίηση των αλγορίθμων και την εναρμόνισή τους με τις ανάγκες της σύγχρονης ιατρικής, με στόχο την ανάπτυξη πιο αξιόπιστων και αποδοτικών συστημάτων διάγνωσης.

Βιβλιογραφία

Ελληνική Βιβλιογραφία

[1] Ηλιάδης, Λ., Παπαλεωνίδας Α., ΥΠΟΛΟΓΙΣΤΙΚΗ ΝΟΗΜΟΣΥΝΗ & ΕΥΦΥΕΙΣ ΠΡΑΚΤΟΡΕΣ. Εκδόσεις Τζιόλα, Θεσσαλονίκη, 2017.

Διεθνής Βιβλιογραφία

1. Mortality Trends in Chronic Liver Disease and Cirrhosis in the United States, Before and During COVID-19 Pandemic
Kim, Donghee et al.
Clinical Gastroenterology and Hepatology, Volume 19, Issue 12, 2664 - 2666.e2
2. Mortality Trends in Chronic Liver Disease and Cirrhosis in the United States, Before and During COVID-19 Pandemic
Kim, Donghee et al.
Clinical Gastroenterology and Hepatology, Volume 19, Issue 12, 2664 - 2666.e2
3. Xing Wang, Bin Wu, Critical issues in the diagnosis and treatment of liver cirrhosis, *Gastroenterology Report*, Volume 7, Issue 4, August 2019, Pages 227–230,
4. Rajeswari, P. and Reena, G.S. (2010) Analysis of Liver Disorder Using Data Mining Algorithm. *Global Journal of Computer Science and Technology*, 10, 48-52.
5. Hassan, M., Irfan, M., & Ayubi, S.- u-D. (2017). Efficient Prediction of Liver Disease using Selected Attributes. *VFAST Transactions on Software Engineering*, 5(1), 10–18.
6. Priya, M. Banu, P. Laura Juliet, and P. R. Tamilselvi. "Performance analysis of liver disease prediction using machine learning algorithms." *Int. Res. J. Eng. Technol* 5.1 (2018): 206-211.

7. Babu, M. Surendra Prasad, Bendi Venkata Ramana, and Boddu Raja Sarath Kumar. "New automatic diagnosis of liver status using bayesian classification." *Proceedings of the International Conference on Intelligent Network and Computing) ICINC, Kuala Lumpur; Malaysia*. 2010.
8. Barnaghi, Peiman Mamani, Vahid Alizadeh Sahzabi, and Azuraliza Abu Bakar. "A comparative study for various methods of classification." *International Conference on Information and Computer Networks*. Vol. 27. No. 2. 2012.
9. Ramana, B. & Venkateswarlu, N. (2022). ILPD (Indian Liver Patient Dataset) [Dataset]. UCI Machine Learning Repository.

Διαδικτυακές Αναφορές

- 1) <https://www.geeksforgeeks.org/normalization-vs-standardization/>
- 2) <https://machinelearningmastery.com/standardscaler-and-minmaxscaler-transforms-in-python/>
- 3) <https://machinelearningmastery.com/smote-oversampling-for-imbalanced-classification/>
- 4) [Computer Organization and Architecture | Pipelining | Set 1 \(Execution, Stages and Throughput\) - GeeksforGeeks](#)
- 5) [Principal Component Analysis \(PCA\) in Python Tutorial | DataCamp](#)
- 6) [Principal Component Analysis with Python - GeeksforGeeks](#)
- 7) [Scikit-learn SVM Tutorial with Python \(Support Vector Machines\) | DataCamp](#)
- 8) [Maximizing Accuracy: Practical Strategies for SVM Model Optimization - AI Upbeat: Navigating the Future of Artificial Intelligence](#)
- 9) [Stratified K Fold Cross Validation - GeeksforGeeks](#)
- 10) [The C Parameter in Support Vector Machines | Baeldung on Computer Science](#)
- 11) [How to plot ROC curve in Python - GeeksforGeeks](#)
- 12) [The k-Nearest Neighbors \(kNN\) Algorithm in Python – Real Python](#)

13) Python | Decision tree implementation - GeeksforGeeks

14) Naive Bayes Classifier Tutorial: with Python Scikit-learn | DataCamp

15) Your First Deep Learning Project in Python with Keras Step-by-Step - MachineLearningMastery.com

16) Boosting in Machine Learning | Boosting and AdaBoost - GeeksforGeeks

17) Extreme Gradient Boosting (XGBoost) Ensemble in Python - MachineLearningMastery.com

18) A Guide to Bagging in Machine Learning: Ensemble Method to Reduce Variance and Improve Accuracy | DataCamp

19) How to Develop a Bagging Ensemble with Python - MachineLearningMastery.com

20) <https://www.kenhub.com/en/library/anatomy/liver-histology>

21) <https://www.aasld.org/liver-fellow-network/core-series/pathology-pearls/normal-liver-histology-101>

22) https://ftp.cdc.gov/pub/Health_Statistics/NCHS/NHIS/SHS/2018_SHS_Table_A-4.pdf

23) <https://www.statista.com/statistics/1485335/deaths-from-liver-disease-worldwide-since-1980/#statisticContainer>

Πηγές Εικόνων (Διαδίκτυο)

<https://www.evidentlyai.com/classification-metrics/confusion-matrix>

<https://www.simplilearn.com/regression-vs-classification-in-machine-learning-article>

<https://peptiko.gr/en/liver-anatomy-function-common-diseases-and-foods/>

<https://www.niddk.nih.gov/health-information/liver-disease/cirrhosis>